

UNIVERSIDAD POLITÉCNICA DE MADRID
Escuela Técnica Superior de Ingeniería de Sistemas Informáticos



Image Enhancement Utilizando Modelos ResNet

TRABAJO DE FIN DE MÁSTER

Presentado para la obtención del título de Máster por:

Jaime González Delgado

Madrid, 2024



UNIVERSIDAD POLITÉCNICA DE MADRID
Escuela Técnica Superior de Ingeniería de Sistemas
Informáticos



Máster en Aprendizaje Automático y Datos Masivos

Image Enhancement Utilizando Modelos ResNet

TRABAJO DE FIN DE MÁSTER

Presentado para la obtención del título de Máster por:

Jaime González Delgado

Bajo la supervisión de:
Dr. Jesús Bobadilla Sancho

Madrid, 2024

Agradecimientos

Quiero comenzar agradeciendo a mi familia, quienes son el pilar fundamental en mi vida. Su apoyo incondicional y su capacidad para ver siempre lo mejor en mí han sido cruciales para lograr mis metas y crecer como persona.

Además, me gustaría mencionar a mis amigos por estar presentes en los buenos y malos momentos.

Por el momento, cierro mi etapa como estudiante y no me gustaría dejar de agradecer a todos los profesores que han contribuido en mi formación académica en todos estos años. Todos ellos han sido partícipes de mi desarrollo personal y profesional. Especial mención, para el profesorado del Máster en Aprendizaje Automático y Datos Masivos, su dedicación y conocimientos, durante este último curso, han contribuido en mi crecimiento en este campo.

Abstract

The image enhancement field covers a broad set of techniques that seek to improve the visual quality of images for later use in other computer vision tasks or by end users. Some of the techniques in this field include denoising, image colorization and super-resolution. In order to approach these tasks, different methods have been proposed over the last decades. In this context, the development of this Master Thesis explores the impact of deep Convolutional Neuronal Networks (CNNs), specifically ResNet residual networks, on these tasks.

Introduced in 2015, ResNet was initially configured for image classification, proving to have an exceptional performance due to the introduction of skip connections, which help mitigate the vanishing gradient problem and enable the implementation of more complex and deeper networks. In order to adapt these networks for image enhancement tasks, a convolutional autoencoder (CAE), called ResNetAE, is implemented. The encoder in ResNetAE follows the same structure as the ResNet to obtain a compact representation of the input image, which the symmetric decoder, using inverse residual block, employs to reconstruct the image. To evaluate the impact of ResNet on visual image quality enhancements, other symmetric CAE have been built, but instead of adapting ResNet networks, another type of convolutional networks, the VGGs proposed in 2014, are used.

This study compares the performance of both architectures across various image enhancement tasks. The comparison is carried out through quantitative analysis, employing different metrics to measure image similarity, such as mean absolute error (MAE), mean squared error (MSE), peak signal-to-noise ratio (PSNR), and structural similarity index measure (SSIM), complemented by visual analysis.

The results suggest a strong performance of ResNet networks in enhancing the visual quality of images. ResNetAE architectures have not only proven to be more effective in denoising, but have also demonstrated superior capabilities in image colorization and super-resolution techniques compared to VGGAE models. This highlights the versatility and efficacy of ResNet networks in the field of image enhancement. Additionally, slight modifications to ResNetAE are proposed for tasks such as image colorization, to improve detail preservation in the reconstructions. Emphasizing the role that these architectures can play in various computer vision applications.

Keywords: Image enhancement, denoising, image colorization, super-resolution, Convolutional Neural Network, ResNet, Autoencoders.

Resumen

El campo de la mejora de imágenes abarca un amplio conjunto de técnicas que buscan mejorar la calidad visual de las imágenes para luego ser empleadas en otras tareas de la visión por computador o por los usuarios. Algunas de las técnicas de este campo incluyen la eliminación de ruido, el coloreado de imágenes y la superresolución. Para abordar estas tareas, se han propuesto diferentes métodos a lo largo de las últimas décadas. En este contexto, en el desarrollo de este Trabajo Fin de Máster, se explora el impacto que tienen en estas tareas las redes neuronales convolucionales profundas (CNN), concretamente las redes residuales ResNet.

Las redes ResNet, introducidas en 2015, fueron inicialmente configuradas para la clasificación de imágenes, demostrando tener un gran rendimiento gracias a la introducción de las conexiones residuales que permiten mitigar el problema del desvanecimiento del gradiente, posibilitando la implementación de redes más complejas y profundas. Con el fin de adaptar estas redes para las tareas de mejora de imágenes, se implementan unos autoencoders convolucionales (CAE), denominados ResNetAE, cuyo codificador sigue la misma estructura que las ResNet para obtener la representación compacta de la imagen de entrada, que el decodificador simétrico, utilizando bloques residuales inversos, emplea para reconstruir la imagen. Para evaluar el impacto de las redes ResNet en la mejora de la calidad visual de imágenes, se han construido otros CAE simétricos, pero en vez de adaptar las redes ResNet, se utilizan otro tipo de redes convolucionales, las VGG, propuestas en 2014.

En este estudio, se ha comparado el desempeño de ambas arquitecturas en diversas tareas de mejora de imágenes. Esta comparación se realiza mediante el análisis cuantitativo, empleando distintas métricas para conocer la similitud entre imágenes como, el error medio absoluto (MAE), error cuadrático medio (MSE), *Peak Signal-to-Noise Ratio* (PSNR) y *Structural Similarity Index Measure* (SSIM); además se realiza un análisis visual que complementa los resultados aportados por las métricas.

Los resultados obtenidos sugieren un buen rendimiento de las redes ResNet para la mejora de la calidad visual de imágenes. Las arquitecturas ResNetAE no solo han mostrado ser más efectivas en la eliminación de ruido, sino que también han demostrado capacidades superiores en el coloreado de imágenes y en la técnica de la superresolución en comparación con los modelos VGGAE. Demostrando la gran versatilidad y eficacia de las redes ResNet en el campo de la mejora de imágenes. Además, se proponen ligeras modificaciones a los ResNetAE para tareas como el coloreado de imágenes, que permitan mejorar la preservación de detalles en las reconstrucciones. Subrayando el papel que pueden jugar estas arquitecturas en diversas aplicaciones de la visión por computador.

Palabras clave: Mejora de imágenes, eliminación de ruido, coloreado de imágenes, superresolución, Redes Neuronales Convolucionales, ResNet, VGG, Autoencoders.

Índice general

Agradecimientos	i
Abstract	ii
Resumen	iii
Índice de figuras	v
Índice de tablas	vi
Abreviaturas y acrónimos	viii
1 Introducción	1
1.1 Objetivos	2
1.1.1 Objetivo general	2
1.1.2 Objetivos específicos	2
2 Estado del arte	4
2.1 Redes Convolucionales	4
2.1.1 ResNet	5
2.2 Autoencoders	7
2.3 Image Enhancement	8
2.3.1 Eliminación de ruido	8
2.3.2 Coloreado de imágenes	9
2.3.3 Superresolución	9
3 Materiales y métodos	10
3.1 Conjunto de datos	10
3.1.1 MNIST	10
3.1.2 Thumbnails 128x128	11
3.1.3 Landscape Image dataset	12
3.1.4 Labeled Faces in the Wild dataset	12
3.2 Diseño de los modelos	13
3.2.1 ResNet Autoencoder	13
3.2.2 VGGNet Autoencoder	17
3.3 Métricas de evaluación	19
3.3.1 Error Medio Absoluto	20
3.3.2 Error Cuadrático Medio	20
3.3.3 Peak Signal-to-Noise Ratio	20
3.3.4 Structural Similarity Index Measure	21

4	Resultados	22
4.1	Eliminación de ruido en imágenes en blanco y negro	22
4.2	Eliminación de ruido en imágenes a color	25
4.3	Coloreado de imágenes	27
4.4	Superresolución	32
5	Conclusiones	36
5.1	Limitaciones del trabajo	38
5.2	Líneas futuras	38

Índice de figuras

2.1	Aplicación convolución de un filtro bidimensional [23].	4
2.2	Ejemplo de CNN [26].	5
2.3	Bloque residual [8].	6
2.4	Autoencoder [1].	7
2.5	Autoencoder convolucional [23].	8
3.1	Ejemplo de imágenes de la colección MNIST.	11
3.2	Ejemplo de imágenes de la colección Thumbnails 128x128.	11
3.3	Ejemplo de imágenes de la colección Landscape Image.	12
3.4	Ejemplo de imágenes de la colección Labeled Faces in the Wild.	13
3.5	ResNet Autoencoders.	14
3.6	Bloques residuales para reducir la dimensionalidad.	15
3.7	Bloques identidad encoder.	15
3.8	Bloques residuales para incrementar la dimensionalidad.	16
3.9	Bloques identidad decoder.	16
3.10	VGG Autoencoder.	18
4.1	Ejemplo de eliminación de ruido en imágenes en blanco y negro.	24
4.2	Ejemplo de eliminación de ruido en imágenes a color.	27
4.3	Ejemplo de coloreado de imágenes empleando ResNetAE.	29
4.4	ResNetAE con skip connection.	30
4.5	Ejemplo de coloreado de imágenes empleando ResNetAE_skip.	31
4.6	Ejemplo superresolución.	34

Índice de tablas

2.1	Arquitecturas ResNet [8].	6
3.1	Número de parámetros modelos ResNetAE.	17
3.2	Número de parámetros modelos VGGAE.	19
4.1	Hiperparámetros y duración del entrenamiento de los modelos para la eliminación de ruido en imágenes en blanco y negro.	23
4.2	Resultados de la evaluación de los modelos para la eliminación de ruido en imágenes en blanco y negro.	23
4.3	Hiperparámetros y duración del entrenamiento de los modelos para la eliminación de ruido en imágenes a color.	25
4.4	Resultados de la evaluación de los modelos para la eliminación de ruido en imágenes a color.	26
4.5	Hiperparámetros y duración del entrenamiento de los modelos ResNetAE para el coloreado de imágenes.	28
4.6	Hiperparámetros y duración del entrenamiento de los modelos ResNetAE_skip para el coloreado de imágenes.	30
4.7	Resultados de la evaluación de los modelos para el coloreado de imágenes. . .	31
4.8	Hiperparámetros y duración entrenamiento de los modelos para la superresolución de imágenes.	33
4.9	Resultados de la evaluación de los modelos para la superresolución de imágenes.	33

Abreviaturas y acrónimos

UPM Universidad Politécnica de Madrid

TFM Trabajo Fin de Máster

IA Inteligencia Artificial

DNN Deep Neural Network

GPU Unidad de Procesamiento Gráfico

CNN Convolutional Neural Network

ReLU Rectified Linear Unit

ResNet Residual Neural Network

AE Autoencoder.

CAE Convolutional Autoencoder

GAN Generative Adversarial Networks

VGGNet Visual Geometry Group Neural Network

MNIST Modified National Institute of Standards and Technology

MAE Mean Absolute Error

MSE Mean Squared Error

PSNR Peak Signal-to-Noise Ratio

SSIM Structural Similarity Index Measure

Capítulo 1

Introducción

En la actualidad, nos encontramos en un periodo marcado por la digitalización y los rápidos y cambiantes avances tecnológicos que contribuyen a la transformación que nuestra sociedad está experimentando. Estos avances están alterando significativamente la forma en que los seres humanos interactuamos entre nosotros y con el entorno que nos rodea. Podemos observar diversos ejemplos del impacto que tienen estas innovaciones, por ejemplo, las mejoras en los medios de transporte han permitido reducir considerablemente los tiempos de viaje, otro ejemplo, son los avances en las telecomunicaciones con la proliferación del Internet, permitiendo el acceso a enormes cantidades de información y contenido en apenas unos segundos. Sin embargo, la aparición de la inteligencia artificial (IA), quizás sea uno de los avances más destacados en los últimos años. La IA está experimentando un gran crecimiento, adentrándose y revolucionando diversos campos del conocimiento y la investigación, como el procesamiento del lenguaje natural, la visión computacional o el análisis de series temporales, entre otros.

Aunque los fundamentos teóricos de la IA se establecieron hace varias décadas, es en la actualidad cuando percibimos de manera más evidente su impacto y potencial. Si bien los modelos tradicionales de *Machine Learning*, como *Random Forest* [2] o los Árboles de Decisión, o *Decision Trees* [20], han demostrado un gran rendimiento para la resolución de problemas, la proliferación del *Deep Learning*, especialmente a través de las redes neuronales profundas (DNN) [13], ha constituido el factor decisivo en el reciente auge de la IA. Las DNNs han permitido la modelización de problemas complejos que anteriormente haciendo uso de técnicas clásicas de aprendizaje automático no eran posible de conseguir. Esta nueva tecnología se ha visto impulsada por la disponibilidad de grandes volúmenes de datos y significativas mejoras en la capacidad de cómputo, especialmente con el uso de GPUs, lo que permite reducir los entrenamientos de estos modelos a tiempos razonables [12]. Además, la investigación de nuevos algoritmos y arquitecturas de redes neuronales han proporcionado herramientas poderosas para aplicaciones en diferentes áreas.

Una de las áreas de la IA que más crecimiento ha experimentado ha sido la visión computacional, impulsado por la introducción de las redes neuronales convolucionales (CNN) [14]. Esta rama de la IA se enfoca en el desarrollo de métodos que permiten a los ordenadores comprender e interpretar el contenido de las imágenes. Los avances en la fotografía, también, han tenido un papel importante en este crecimiento. Desde su invención en el siglo XIX [28], la tecnología

asociada a la fotografía ha desarrollado una gran evolución, especialmente en lo que respecta a los sensores, permitiendo mejorar tanto la calidad como la resolución de las imágenes capturadas. Además, la proliferación de los *smartphones* con cámaras avanzadas han facilitado la captura de imágenes de alta calidad. Esta mayor accesibilidad para tomar fotografías de calidad ha repercutido en un aumento de las colecciones disponibles para el entrenamiento de redes neuronales que buscan resolver problemas de la visión por computador [12].

El uso de las imágenes ha experimentado una transformación importante, incorporándose en investigaciones de diversas disciplinas. Por ejemplo, en la medicina, las imágenes ayudan en el diagnóstico de algunas enfermedades, mientras que en campos como la conducción autónoma y la teledetección, los datos provenientes de los sensores son fundamentales para el análisis del entorno. El desarrollo de la visión computacional puede ser de gran ayuda en estos estudios permitiendo el empleo de nuevos modelos más precisos y eficaces para la detección de anomalías en imágenes, ayudando el diagnóstico de enfermedades [15], o la identificación de señales y elementos claves para la conducción autónoma [10]. Además, en la teledetección, la segmentación de imágenes de campos de cultivo mediante técnicas de visión computacional contribuye para una mejor gestión de recursos [29]. La calidad de los datos es crucial para la obtención de un buen rendimiento en los modelos, lo que pone de manifiesto la importancia de contar con imágenes de alta calidad. De esta necesidad surge la disciplina de la visión por computador, *Image Enhancement*, que se centra en mejorar la calidad visual de las imágenes para su posterior uso.

En este Trabajo Fin de Máster, se aborda la utilización de redes neuronales residuales (ResNet) para la mejora de imágenes. Los modelos ResNet fueron introducidos por un grupo de investigadores de Microsoft [8], demostrando ser altamente efectivos en diversas tareas de la visión computacional gracias a su arquitectura innovadora.

1.1 Objetivos

1.1.1 Objetivo general

El propósito general de este TFM es investigar y desarrollar técnicas avanzadas para la mejora de imágenes utilizando las redes convolucionales ResNet. Este estudio se enfoca en comparar y contrastar la efectividad de distintas arquitecturas ResNet en técnicas de *image enhancement*, tales como la eliminación de ruido, el coloreado de imágenes y la superresolución. La finalidad es adaptar estas redes, originalmente aplicadas en otros ámbitos de la visión computacional, al proceso de mejora de imágenes.

1.1.2 Objetivos específicos

Para alcanzar el objetivo general propuesto, se han establecido una serie de objetivos específicos:

1. **Exploración del estado del arte:** este objetivo busca establecer una base de conocimiento sobre las redes neuronales ResNet y las técnicas de mejora de imágenes.
2. **Preparación de los datos:** este objetivo implica la recopilación, limpieza y preprocesado de las colecciones de imágenes necesarias para el entrenamiento y evaluación de las

arquitecturas ResNet, para cada técnica de mejora de imágenes estudiada.

3. **Implementación y evaluación:** este objetivo se refiere al desarrollo e implementación de las arquitecturas. Utilizando la librería de Python, TensorFlow (<https://www.tensorflow.org/>, último acceso Junio 2024) para el entrenamiento y optimización de los modelos. Posteriormente, se emplearán diversas métricas que permiten establecer una evaluación de la efectividad de cada modelo en las tareas de eliminación de ruido, coloreado de imágenes y superresolución.
4. **Análisis de los resultados:** este objetivo plantea la interpretación de los resultados obtenidos durante la evaluación de los modelos, permitiendo identificar fortalezas y debilidades de cada modelo. Además, se discutirán las posibles implicaciones para futuras investigaciones y aplicaciones prácticas.

Capítulo 2

Estado del arte

2.1 Redes Convolucionales

Las redes convolucionales (CNN) son un tipo de red neuronal utilizadas mayoritariamente en imágenes, propuestas por Yann LeCun en 1998 [14] con la introducción de la arquitectura LeNet-5. Esta clase de redes se centran en el concepto de convolución, que en el caso de las imágenes se trata de la aplicación de un filtro bidimensional, que se va desplazando por la muestra. El resultado de la aplicación da lugar a los mapas de activación, como se puede observar en la Figura 2.1.




Figura 2.1: Aplicación convolución de un filtro bidimensional [23].

Antes del desarrollo de las CNN, el diseño de filtros para resaltar características en las imágenes era una tarea manual, donde los investigadores se dedicaban a la creación y ajuste de filtros específicos para diversas características visuales, por ejemplo, el filtro de Sobel para la detección de bordes [5]. Sin embargo, con la introducción de las CNN, estos filtros pasaron a generarse automáticamente en el proceso de aprendizaje del modelo. Estas redes aprenden a obtener los filtros más relevantes de acuerdo con las colecciones empleadas en el entrenamiento, ajustando sus pesos a través de la minimización de la función de pérdida. Este proceso de optimización, común a todas las redes neuronales, permite a las CNN identificar y extraer las características de una imagen de una manera eficiente y sin necesidad de intervenir

manualmente en el diseño de los filtros [23].

Además de las capas convolucionales, que aplican los filtros sobre las imágenes para extraer las características, estas redes incluyen capas de activación aplicadas tras las convoluciones. Estas capas introducen no linealidad empleando funciones como ReLU, *Rectified Linear Unit*, permitiendo que los modelos aprendan patrones más complejos [18]. Otras capas comúnmente utilizadas son las de *Pooling*, que permiten reducir la dimensionalidad de los mapas de activación manteniendo las características más importantes. La implementación más común de esta clase de capas es la *max-pooling*, que obtiene el valor máximo de una ventana de la imagen. Y por último, para tareas de clasificación o regresión, se incluyen al final capas densas que combinan las características extraídas por las capas de convolución para resolver la tarea objetivo [25]. En la Figura 2.2, se representa un esquema de CNN con las distintas capas descritas anteriormente.




Figura 2.2: Ejemplo de CNN [26].

En definitiva, las redes neuronales convolucionales han supuesto una gran revolución en el campo de la inteligencia artificial, especialmente en el área de la visión por computador, proporcionando poderosas herramientas para la extracción de características en datos espaciales, como las imágenes. Las CNN han mostrado un gran desempeño en tareas de clasificación de objetos, reconocimiento y segmentación de imágenes.

2.1.1 ResNet

La evolución de las CNN ha evidenciado que aumentar la profundidad de la red tiende a mejorar el rendimiento de los modelos para resolver un problema. No obstante, este incremento en la profundidad de la red puede provocar la aparición de dos problemas, el sobreajuste y el *vanishing gradient*. El sobreajuste, se produce cuando un modelo tiene un gran rendimiento con los datos de entrenamiento pero no es capaz de generalizar a datos nunca vistos. Este fenómeno se puede controlar mediante el empleo de técnicas como *dropout* o *batch normalization*. En cuanto al desvanecimiento de gradiente, que se produce cuando los gradientes utilizados para actualizar los pesos se vuelven extremadamente pequeños durante la propagación hacia atrás lo que dificulta una actualización eficaz de los pesos de la red [22]. Este problema puede verse

reducido con el empleo de funciones de activación como ReLU, cuya derivada no tiende con rapidez a cero.

Con el objetivo de minimizar el problema de *vanishing gradient*, los investigadores de Microsoft proponen las Redes Neuronales Residuales, ResNet [8], que introducen unos atajos que permiten la propagación de los gradientes directamente desde capas más profundas hasta las menos profundas. Estos atajos reciben el nombre de conexiones residuales o *skip connections* que permiten el salto de varias capas. En la Figura 2.3, se representa la estructura de bloque residual propuesto, donde se observa un flujo principal con distintas capas y una conexión residual salta estas capas.




Figura 2.3: Bloque residual [8].

El bloque residual básico se define como $y = \text{ReLU}(\mathcal{F}(x, \{W_i\}) + x)$, donde x es la entrada del bloque, $\mathcal{F}(x, \{W_i\})$ representan las capas convolucionales aplicadas a x , y donde, y representa la salida del bloque. Esto implica que la salida del bloque residual se obtiene aplicando la función de activación ReLU a la suma entre la entrada del bloque y la salida de las capas convolucionales. Cada capa convolucional está seguida por una operación de normalización por lotes y una función de activación ReLU. Como se indica en la Tabla 2.1, el bloque residual puede contar con dos o tres capas de convolución. Además, en los casos donde se reduce la dimensionalidad para permitir la suma de ambos flujos, se aplica una convolución en la conexión residual ajustando su dimensión para la suma.

Tabla 2.1: Arquitecturas ResNet [8].

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2_x	56×56	3×3 max pool, stride 2				
		$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

Desde su aparición, las redes ResNet han presentado un gran rendimiento, posibilitando el desarrollo de arquitecturas más complejas, mitigando el problema asociado del desvanecimiento de gradiente. Estas redes han superando varios *benchmarks*, como el de clasificación de

imágenes de la colección ImageNet. Debido a este gran rendimiento, también se han empleado en otras áreas como la segmentación de imágenes o en el campo médico para la detección de enfermedades a partir de imágenes de diagnóstico [16].

2.2 Autoencoders

Los autoencoders (AE) son un tipo de red neuronal no supervisada diseñados para aprender una representación compacta de los datos de entrada. Estas redes se componen de dos partes principales, el *encoder*, que reduce la dimensionalidad de los datos de entrada obteniendo la representación comprimida, a partir de la cual, el *decoder*, reconstruye la entrada original. El objetivo principal de un AE es minimizar la diferencia entre los datos de entrada y los datos reconstruidos [1]. La Figura 2.4 muestra el diseño de un autoencoder, donde se observa que tras ser procesada por el *encoder*, la imagen de entrada se comprime en una representación que luego pasa por el *decoder* obteniendo la imagen reconstruida.




Figura 2.4: Autoencoder [1].

Los primeros AE seguían una estructura basada en las redes neuronales clásicas, compuestas por múltiples capas de neuronas. Algunas de las primeras tareas donde se hacen uso de estas redes son la compresión de datos y la detección de anomalías. En el primer caso, los AE aportan una gran ventaja al obtener una representación más compacta con una mínima pérdida de información, lo que reduce la capacidad de almacenamiento requerida. En la detección de anomalías, estas redes se emplean para detectar si existe una discrepancia significativa entre la entrada y la salida, lo que puede indicar la presencia de alguna anomalía en los datos de entrada.

Con la evolución de las redes neuronales y la aparición de nuevas arquitecturas como las CNN, se han adaptado estos nuevos modelos a los AE, dando lugar a los denominados autoencoders convolucionales (CAE). Los CAE aprovechan las ventajas que aportan las CNN para manejar datos visuales, como imágenes y vídeos, mediante el empleo de capas convolucionales en lugar de capas densas para la extracción de las características, preservando la información de la estructura espacial. En los CAE, el *encoder* aplica filtros convolucionales para obtener la representación comprimida de la imagen de entrada. Luego, el *decoder*, con el uso de convoluciones transpuestas reconstruye la imagen, recuperando la información espacial original. La Figura 2.5 muestra la arquitectura de un CAE, que, además del *encoder* y el *decoder*, puede incluir entre ambos una etapa opcional denominada capa latente. Esta capa funciona como un AE clásico donde se emplean capas densas para obtener una representación

más compacta si fuese necesario [27].




Figura 2.5: Autoencoder convolucional [23].

Los autoencoders, y particularizando en este trabajo los autoencoders convolucionales, han supuesto un gran avance para la manipulación y análisis de datos espaciales. Su capacidad para preservar características espaciales locales han supuesto una mejoría en tareas como la eliminación de ruido [6], la superresolución [34] o la reconstrucción de imágenes [32].

2.3 Image Enhancement

El campo de la visión por computador es un área de estudio muy amplio y con múltiples ramas especializadas, cada una enfocada en aspectos específicos del procesamiento y análisis de imágenes. Entre las ramas principales se incluye el reconocimiento y detección de objetos, la segmentación de imágenes, y la mejora de imágenes.

La mejora de imágenes, o *image enhancement*, se centra en la mejora de la calidad visual de las imágenes a través de técnicas como la eliminación de ruido, el coloreado de imágenes o la superresolución. Esta disciplina juega un papel fundamental en la visión computacional, ya que puede utilizarse como una etapa previa que mejora las imágenes antes de ser procesadas por otras aplicaciones, pudiendo resultar en una mejora del rendimiento de estas aplicaciones. Por ejemplo, mejorar la resolución de una imagen puede resultar en una mejora del desempeño de aplicaciones para la identificación de objetos. Esta rama puede tener un impacto directo en diferentes dominios prácticos como la medicina mejorando la calidad de las imágenes de diagnóstico o en la seguridad pudiendo mejorar el detalle de las grabaciones para la detección de personas o eventos.

Este TFM se ha centrado en el estudio y aplicación de diversas técnicas de *image enhancement*, incluyendo la eliminación de ruido, el coloreado de imágenes y la superresolución.

2.3.1 Eliminación de ruido

La eliminación de ruido es una tarea fundamental en el procesamiento de imágenes, ya que las imágenes pueden contener un ruido asociado, que se produce por diversas fuentes, como

el proceso de adquisición o compresión de las imágenes. Este ruido puede tener un impacto en la calidad visual de las imágenes, dificultando su posterior análisis. En respuesta a esta problemática, se han desarrollado diferentes técnicas a lo largo del tiempo para mitigar el impacto que tiene el ruido en las imágenes.

Las técnicas tradicionales para la eliminación de ruido se basan en métodos estadísticos y de filtrado, que sentaron las primeras bases de esta rama. Sin embargo, la introducción de las CNNs han supuesto un gran avance en la calidad de los resultados obtenidos. Las redes convolucionales aportan una mayor flexibilidad y capacidad para aprender representaciones más complejas, que resultan en una mejor preservación de los detalles. No obstante, estas redes presentan un inconveniente al requerir grandes colecciones de datos para el entrenamiento. La escasez de conjuntos de imágenes adecuados para esta tarea ha llevado al empleo de datos sintéticos, es decir, añadiendo ruido de manera artificial a colecciones de imágenes concebidas para otras tareas. Este enfoque, aun siendo útil, puede resultar no ser tan efectivo en casos reales [4].

2.3.2 Coloreado de imágenes

El coloreado de imágenes es el proceso donde a las imágenes en escala de grises se le agrega información referente al color. Esta técnica de la mejora de imágenes permite la restauración de fotografías antiguas, recuperando la información cromática que puede ser relevante para una mejor comprensión o análisis de la imagen.

Inicialmente, las técnicas desarrolladas para el coloreado de imágenes eran esencialmente manuales, requiriendo la intervención de humana. Para que la asignación de colores fuese fiel a la realidad, las personas encargadas debían ser conocedoras del contexto de la fotografía. Posteriormente, surgen métodos semi-automáticos, donde algoritmos de baja complejidad propagan el color desde áreas manualmente coloreadas hacia el resto de la imagen. La introducción de redes convolucionales supuso una gran revolución en este área. Al ser las CNNs capaces de aprender y capturar características complejas, permitieron una mejora tanto en la automatización como en la calidad del coloreado [35]. El desarrollo de las redes generativas (GAN), también supusieron un gran avance facilitando resultados más realistas.

2.3.3 Superresolución

La superresolución es una técnica de la mejora de imágenes que tiene como objetivo el aumento de la resolución de una imagen, mejorando su calidad visual y su utilidad en diversas aplicaciones. Para ello en el proceso de superresolución se genera una imagen de alta resolución a partir de imágenes de baja resolución.

Las técnicas de superresolución han evolucionado desde los métodos tradicionales hasta la incorporación de redes neuronales convolucionales. Inicialmente, técnicas como la interpolación bilineal y bicúbica proporcionan una solución rápida y sencilla. Posteriormente, se emplean métodos basados en modelos simples que permiten una mejora en la preservación de los detalles. Pero al igual que ha ocurrido en la mayoría de ramas del campo de la visión computacional, las CNN han supuesto un gran avance mejorando la calidad de las imágenes de alta resolución generadas [33].

Capítulo 3

Materiales y métodos

3.1 Conjunto de datos

Para la elaboración de este trabajo, se han requerido múltiples colecciones de imágenes. Estas colecciones han sido divididas en dos subconjuntos: el de entrenamiento, que se empleará para entrenar y ajustar los pesos de los modelos, y el de pruebas, destinado a evaluar el rendimiento de las diferentes redes implementadas. También, se ha requerido de un preprocesamiento de las colecciones para adaptarlas a las técnicas de *image enhancement* aplicadas en este TFM.

3.1.1 MNIST

La conocida base de datos MNIST, *Modified National Institute of Standards and Technology*, es una extensa colección imágenes en blanco y negro de dígitos manuscritos del 0 al 9. Este conjunto de datos contiene 60.000 imágenes de 28x28 píxeles, destinadas inicialmente al entrenamiento de modelos de clasificación. Además, cuenta con 10.000 imágenes adicionales para pruebas. En todas ellas, los dígitos se encuentran centrados en la imagen [31]. Este dataset es empleado con gran frecuencia en diversas aplicaciones de *Machine learning* y de visión por computadora debido a su simplicidad y tamaño manejable. En el presente trabajo, estos datos se emplean en el entrenamiento de los modelos orientados a la eliminación de ruido en imágenes en blanco y negro, siendo necesario un preprocesado de las imágenes para adaptar la colección a la tarea.

Este preprocesado busca generar, a partir de las imágenes originales, versiones con ruido que serán las entradas del modelo. Inicialmente, se realiza la normalización de los valores de los píxeles, obteniendo como resultado de este proceso la colección de imágenes donde el valor que puede tomar el píxel oscila entre 0 y 1. Para que estas imágenes puedan ser procesadas por los modelos implementados, es necesario aumentar el tamaño de las imágenes de 28x28 a 32x32 píxeles. Por último, se añade ruido gaussiano, caracterizado por seguir una distribución normal con media μ y desviación estándar σ , cuya función de densidad viene descrita por la ecuación 3.1. En este estudio, se ha establecido el valor de la media en 0 con una desviación de 0,6 para determinar el nivel de ruido que se le añade a la imagen. La Figura 3.1 muestra varios ejemplos de imágenes de la colección MNIST en la fila superior, y sus correspondientes

versiones con ruido en la fila inferior.




Figura 3.1: Ejemplo de imágenes de la colección MNIST.

$$p(x) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right) \quad (3.1)$$

3.1.2 Thumbnails 128x128

Esta colección contiene 70.000 imágenes de rostros humanos con una resolución de 128x128, mostrando una gran variación en el fondo de la imagen, así como en la edad y etnia de las personas retratadas. Fue desarrollada por el equipo de NVIDIA para generar un *benchmark* para las redes generativas (GANs) [11]. Puede descargarse desde el repositorio GitHub del proyecto de NVIDIA (<https://github.com/NVlabs/ffhq-dataset>, último acceso en Junio de 2024) o desde la plataforma Kaggle (<https://www.kaggle.com/datasets/imcr00z/flickr-faces-70k-thumbnails-128x128>, último acceso en Junio de 2024).



Figura 3.2: Ejemplo de imágenes de la colección Thumbnails 128x128.

Para este trabajo se ha hecho empleo de las 20.000 primeras imágenes que componen el conjunto de entrenamiento, contando con las siguientes 2.000 fotografías para conformar el conjunto de prueba. Al igual que la colección anterior, esta colección se emplea para entrenar modelos de eliminación de ruido, pero en esta ocasión en imágenes a color. Siguiendo la metodología empleada en la colección MNIST, primero se normalizan los valores de los píxeles

de los tres canales que componen la imagen. Una vez normalizadas las imágenes, se añade ruido gaussiano con una media (μ) de 0 y una desviación estándar (σ) de 0,2. A diferencia del conjunto MNIST, en este caso no se precisa de un ajuste del tamaño de las imágenes para ser procesada por los modelos. La Figura 3.2, muestra varios ejemplos de esta colección en la fila superior, y sus correspondientes versiones con ruido en la fila inferior.

3.1.3 Landscape Image dataset

La colección *Landscape Image* está diseñada para el entrenamiento de modelos que colorean imágenes en blanco y negro. Contiene 7.129 fotografías de diversos lugares, como calles, edificios o montañas, entre otros. Cada imagen de la colección cuenta con una versión en color y otra en blanco y negro, ambas con un tamaño de 150x150 píxeles. Este conjunto de datos se encuentra publicado en la plataforma de Kaggle (<https://www.kaggle.com/datasets/theblackmamba31/landscape-image-colorization/data>, último acceso en Junio 2024).



Figura 3.3: Ejemplo de imágenes de la colección Landscape Image.

Dado que esta colección ya está orientada al coloreado de imágenes, el preprocesado de las muestras es relativamente sencillo. Siendo únicamente necesario ajustar el tamaño de las fotografías a 160x160 píxeles para su procesamiento por las redes implementadas y normalizar los valores de los píxeles. Por otro lado, se realiza una división del conjunto en un subconjunto de entrenamiento, que comprende el 80 % de las muestras (5.703 imágenes), y un subconjunto de prueba que abarca el 20 % restante. La Figura 3.3, muestra varios ejemplos de esta colección con las imágenes en color en la fila superior, y sus correspondientes versiones en blanco y negro en la fila inferior.

3.1.4 Labeled Faces in the Wild dataset

Labeled Faces in the Wild (LFW) es una base de datos con fotografías de rostros humanos, diseñada inicialmente para estudiar el problema del reconocimiento facial sin restricciones. Esta colección fue creada por investigadores de la universidad de Massachusetts y cuenta con 13.233 imágenes de tamaño 250x250 píxeles [9]. Puede descargarse desde su web (<https://vis-www.cs.umass.edu/lfw/>, último acceso Junio 2024), aunque también se encuentran disponibles en la plataforma Kaggle (<https://www.kaggle.com/datasets/jessicali9530/lfw-dataset>, último acceso Junio 2024).



Figura 3.4: Ejemplo de imágenes de la colección Labeled Faces in the Wild.

Esta colección, en este trabajo, se emplea para entrenar modelos de superresolución. Por ello, al igual que ocurre en las otras colecciones, es necesario realizar un preprocesado, que en este caso incluye la reducción de la resolución en un 20 %, habiendo sido necesario la implementación de una función para ello. Pero previo a la aplicación de esta función, se ajusta el tamaño de las imágenes, pasando de los 250x250 a 160x160 píxeles y se normalizan los valores de los píxeles. La colección se divide en un subconjunto de entrenamiento, que incluye el 80 % de las muestras, y un conjunto de prueba con el 20 % restante. La Figura 3.4, muestra varios ejemplos de esta colección en la fila superior, y sus correspondientes versiones de menor resolución en la fila inferior.

3.2 Diseño de los modelos

Para el desarrollo de este TFM finalmente se ha optado por hacer empleo de autoencoders convolucionales debido a su capacidad para capturar y representar características complejas de las imágenes [3], permitiendo la reconstrucción de imágenes donde se mejoran aspectos como la resolución o el ruido que contiene una imagen. La combinación de estas arquitecturas con las ResNet, cuya estructura de conexiones residuales mitiga el problema de *vanishing gradient* en redes profundas, permite contar con un enfoque robusto para la mejora de imágenes [17].

3.2.1 ResNet Autoencoder

Los primeros modelos que se han desarrollado en el marco de este TFM se han denominado ResNet AutoEncoders (ResNetAE). Las ResNetAE se tratan de un tipo de *autoencoder* que combinan la estructura de las redes ResNet, permitiendo la codificación y decodificación de los datos haciendo uso de las conexiones residuales. Estas arquitecturas están divididas en dos componentes principales: el *encoder* y el *decoder*. El *encoder* se encarga de reducir la información de la muestra, generando una representación comprimida. Esta representación comprimida es utilizada en la segunda parte de la red, el *decoder*, para reconstruir la imagen.

En la Figura 3.5, se muestra el diseño de las tres arquitecturas implementadas durante el desarrollo de este trabajo. En cada una de ellas se aprecia que el *encoder*, la columna izquierda de cada red, sigue la misma estructura que los tres diseños de red ResNet propuestos en la




Figura 3.5: ResNet Autoencoders.

publicación original [8], ResNet-18, ResNet-34 y ResNet-50, con la diferencia de que se ha eliminado la capa densa final destinada a la clasificación multiclase de imágenes en la concepción original de estas redes. La estructura del *encoder* consta de cinco etapas convolucionales. La primera etapa está compuesta por una convolución inicial con un filtro de tamaño 7x7 y un *stride* de 2, seguida de una normalización por lotes usando la función de activación ReLU, permitiendo reducir la dimensionalidad de la muestra de entrada. Tras la convolución se aplica un *Max-Pooling* de desplazamiento dos, volviendo a reducir la dimensionalidad espacial.

Cada una de las cuatro siguientes etapas convolucionales, destacadas con diferentes colores en la Figura 3.5, están conformadas por el número de bloques residuales establecidos en los diseños originales. En la red ResNetAE-18, que sigue la estructura de la ResNet-18, cada etapa convolucional cuenta con dos bloques residuales. En cambio, la red ResNetAE-34, con

la estructura de la ResNet-34, y en la ResNetAE-50, basada en la ResNet-50, las etapas están conformadas por 3, 4, 6 y 3 bloques residuales, respectivamente.




Figura 3.6: Bloques residuales para reducir la dimensionalidad.




Figura 3.7: Bloques identidad encoder.

El camino principal de los módulos residuales varía en función del tipo de arquitectura, pudiendo estar compuesto por dos o tres capas convolucionales. En el caso de las arquitecturas ResNetAE-18 y ResNetAE-30, cada etapa convolucional consta de dos capas con filtros 3x3. Por el contrario, los bloques de la red ResNetAE-50 están compuestos por tres capas convolucionales, la primera y última con tamaño de *kernel* 1x1, y la capa intermedia con tamaño de filtro 3x3. Tras cada capa convolucional se aplica una normalización por lotes.

Las redes ResNet integran las conexiones residuales, atajos que contribuyen a disminuir el problema del *vanishing gradient*. Al no emplear las capas *pooling* para reducir la dimensionalidad, es necesario incorporar una convolución seguida por una normalización por lotes a la conexión residual para ajustar la dimensión de la conexión residual con la del flujo principal, permitiendo aplicar la suma entre ambos flujos, como se ilustra en la Figura 3.6. Los bloques residuales que incluyen la reducción de la dimensionalidad, son los primeros en cada etapa convolucional y son seguidos por los bloques identidad. Los bloques identidad, representados en la Figura 3.7, mantienen la estructura descrita, con la diferencia de no aplicar ninguna convolución en la conexión residual, ya que no se tiene que reducir la dimensión para realizar la suma de flujos tras la que se emplea una función de activación ReLU.

El número de filtros de cada capa convolucional varía según la etapa convolucional. Esto se refleja en la Figura 3.5, donde se indica entre paréntesis el número de filtros correspondientes a las convoluciones de cada bloque residual. Como se observa en el *encoder*, el número de filtros aumenta progresivamente con cada etapa convolucional, mientras que en *decoder*

van disminuyendo en cada etapa convolucional. Además, en todas las capas se aplica un desplazamiento del filtro de 1, excepto en aquellas capas donde la figura muestra “/2” después del número de filtros, lo que indica un *stride* de 2 en estas capas.

Tras la aplicación del *encoder*, se obtiene una representación de la imagen que el *decoder* emplea para realizar la reconstrucción de la imagen. El diseño propuesto para el *decoder* busca ser simétrico respecto al *encoder*. Como se representa en la Figura 3.5, tanto el número de etapas convolucionales como el número de filtros y bloques residuales por etapa son idénticos en ambas partes del autoencoder. La principal diferencia radica en los bloques residuales del *decoder*, que utilizan convoluciones transpuestas en lugar de las convoluciones habituales. Tras el procesamiento en estos bloques residuales inversos, se incluye una última capa convolucional transpuesta, que permite obtener la imagen reconstruida con la misma resolución que la de entrada. En esta última capa, el número de filtros depende del número de bandas de la imagen reconstruida. Al igual que en la primera capa convolucional del *encoder*, el *stride* se establece en dos y el tamaño del filtro es de 7×7 , y donde se aplica una función de activación sigmoide, dada la normalización de las imágenes originales con valores de píxel entre 0 y 1. Aplicándose una normalización por lotes tras cada capa convolucional transpuesta, como ocurría tras cada capa convolucional.




Figura 3.8: Bloques residuales para incrementar la dimensionalidad.




Figura 3.9: Bloques identidad decoder.

La Figura 3.8 muestra la estructura de los bloques residuales inversos que permiten aumentar la dimensión. Estos bloques siguen un esquema similar al de los bloques residuales convencionales, con un flujo principal compuesto por dos capas convolucionales transpuestas de tamaño 3×3 en las arquitecturas ResNetAE-18 y ResNetAE-34, y tres capas convolucionales transpuestas para la ResNetAE-50, con tamaños de filtro 1×1 , 3×3 y 1×1 , respectivamente. Además, se

cuenta con otra convolución transpuesta en la conexión residual para ajustar la dimensión y para poder realizar la suma entre ambos caminos. Mientras, la Figura 3.9 representa el bloque identidad inverso donde las convoluciones han sido sustituidas por convoluciones transpuestas. Al igual que ocurre en los bloques identidad del *encoder*, no se aplica ninguna convolución en la conexión residual.

En Tabla 3.1, se recogen el número de parámetros de cada una de las redes implementadas. El diseño con la menor cantidad de parámetros es el ResNetAE-18, con algo menos de 30 millones, siendo la red de menor tamaño. La segunda arquitectura implementada, ResNetAE-34, contiene aproximadamente 50 millones de parámetros en total, suponiendo un gran incremento respecto al modelo ResNetAE-18. Y por último, el modelo con mayor tamaño es el ResNetAE-50, superando los 52 millones de parámetros en total, aproximadamente 2 millones más que el ResNetAE-34. El número de parámetros de una red puede influir en su eficacia para la resolución de tareas más complejas, así como, en los requisitos computacionales y el tiempo de entrenamiento. Además, un mayor número de parámetros puede incrementar el riesgo de sobreajuste, especialmente si la tarea no justifica el empleo de redes de gran tamaño. Estas consideraciones se deben tener en cuenta a la hora de escoger el modelo que se emplea.

Tabla 3.1: Número de parámetros modelos ResNetAE.

Modelo	#param. encoder	#param. decoder	#param. totales
ResNetAE-18	12.604.352	17.248.911	29.853.263
ResNetAE-34	22.723.648	27.368.207	50.091.855
ResNetAE-50	23.587.712	28.238.031	52.425.743

3.2.2 VGGNet Autoencoder

Con el fin de contar con otras redes *autoencoders* simétricas como las propuestas, con las que poder comparar el impacto de las redes ResNet en las tareas de mejora de imágenes, se han implementado un conjunto de redes basadas en la arquitectura CNN del estado del arte VGGNet [25]. Las redes VGG, son un tipo de arquitectura CNN propuestas en el año 2014 por el grupo de la Universidad de Oxford *Visual Geometry Group*, cuyas siglas dan nombre a esta clase de redes.

La estructura de estas redes está compuesta por una serie de bloques secuenciales, constituidos por un número específico de capas convolucionales con filtros de tamaño 3x3. Al final de cada bloque, se aplica una capa de *MaxPooling* con tamaño 2x2, que permite reducir progresivamente la dimensión espacial de la imagen de entrada. A medida que se avanza en la red, el número de filtros de las convoluciones de cada bloque va incrementándose, típicamente duplicándose. Al ser diseñadas inicialmente para la clasificación de imágenes, cuentan con varias capas densas en su parte final. Las versiones más empleadas de este tipo de redes son la VGG-16, con 16 capas en total, de las cuales 13 son convolucionales distribuidas en 5 bloques y 3 son capas densas; y la VGG-19, con 19 capas, 16 de ellas convolucionales divididas en 5 bloques y las 3 restantes son capas densas.

Para la implementación de estas redes se ha seguido el esquema de los AE. Donde se cuenta con un *encoder*, que comprime la información de la imagen de entrada siguiendo la estructura de




Figura 3.10: VGG Autoencoder.

las VGG, y un *decoder* que reconstruye la imagen a partir de la representación del *encoder*. La Figura 3.10 ilustra el esquema de los dos modelos implementados, VGGAE-16 y VGGAE-19.

El *encoder* del VGGAE-16, sigue la misma estructura que la red VGG-16, pero, al igual que en la implementación de los ResNetAE, se eliminan las capas densas destinadas a la clasificación de imágenes. Por lo tanto, el *encoder* está compuesto por 5 bloques convolucionales con 2, 2, 3, 3 y 3 capas convolucionales, respectivamente. Tras cada bloque, se aplica una capa *MaxPooling* para reducir la dimensionalidad de la muestra. En el VGGAE-19, el *encoder* también cuenta con 5 bloques convolucionales, representados cada uno por un color en la Figura 3.10, pero en lugar de tener 3 capas convolucionales en los últimos 3 bloques, como ocurría en el VGGAE-16, estos tres últimos bloques están compuestos por 4 capas convolucionales cada uno. En ambas redes, las capas convoluciones emplean una función de activación ReLU y un desplazamiento de filtro de uno. Además, el número de filtros en las capas convoluciones de cada bloque es

el mismo en ambas arquitecturas, 64, para el primer bloque, 128, en el segundo, 256, en el tercero, y en los últimos dos bloques el número de filtros es de 512.

El *decoder* de estas arquitecturas se diseña para ser simétrico al *encoder*, por ello, como refleja la Figura 3.10, esta sección de la red también se compone de cinco bloques. La diferencia radica en que estos módulos emplean las convoluciones transpuestas. En cada bloque, la primera convolución transpuesta tiene un *stride* de 2, que permite incrementar la dimensionalidad de la muestra, con el fin de alcanzar la resolución original de la imagen en la salida de la red. El resto de capas convolucionales transpuestas cuentan con un *stride* de 1. El número de filtros en cada bloque de convoluciones transpuestas es el mismo que su bloque convolucional homólogo, exceptuando la última convolución transpuesta del último módulo del *decoder*, donde el número de filtros corresponde a los canales de la imagen reconstruida. A diferencia del resto de capas de convolución transpuestas, que emplean la función de activación ReLU, esta última capa emplea la función de activación sigmoide, al tener normalizados los valores de los píxeles de las imágenes entre 0 y 1.

En la Tabla 3.2, se recopila el número de parámetros empleados por cada una de las arquitecturas implementadas. El modelo de menor tamaño, VGGAE-16, cuenta con más 31 millones de parámetros en total, de los cuales menos de 15 millones pertenecen al *encoder*, mientras que el *decoder* contiene aproximadamente 17 millones de parámetros. Por otro lado, la arquitectura VGGAE-19, la de mayor tamaño de las VGGAE implementadas, posee un total de más de 42 millones de parámetros, distribuidos entre el *encoder* y *decoder*, con aproximadamente 20 millones y 22 millones parámetros, respectivamente.

Tabla 3.2: Número de parámetros modelos VGGAE.

Modelo	#param. encoder	#param. decoder	#param. totales
VGGAE-16	14.714.688	17.037.059	31.751.747
VGGAE-18	20.024.384	22.346.755	42.371.139

3.3 Métricas de evaluación

Con el fin de poder evaluar y comparar el desempeño de los distintos modelos en las diferentes tareas de *image enhancement* desarrolladas en este trabajo, que incluyen la eliminación de ruido, el coloreado de imágenes y la superresolución, se han empleado diversas métricas. Estas métricas son de gran importancia para medir la calidad de los modelos entrenados y proporcionar una evaluación cuantitativa de su rendimiento. Entre las métricas se incluyen el PSNR, *Peak Signal-to-Noise Ratio*, y el SSIM, *Structural Similarity Index Measure*, empleadas en múltiples publicaciones debido a su capacidad para evaluar la calidad de imágenes en contextos de restauración y mejora visual. Además, se utilizan otras métricas clásicas como el MSE, *Mean Squared Error*, y el MAE, *Mean Absolute Error*, que aportan información valiosa sobre la precisión del modelo al cuantificar la diferencia entre los valores de los píxeles de la imagen generada y la original. La utilización de estas métricas permite realizar una comparación objetiva entre los modelos, permitiendo identificar los más efectivos para cada tarea específica.

3.3.1 Error Medio Absoluto

El error medio absoluto, MAE, de sus siglas en inglés, es una de las métricas más usadas en la validación de modelos de regresión debido a su simplicidad y efectividad. Esta métrica se adapta fácilmente para su aplicación en imágenes, donde se emplea para computar la media de las diferencias absolutas entre los valores de los píxeles de dos imágenes [19]. El MAE se define mediante la ecuación 3.2, en la que x_i y y_i representan los valores de los píxeles en la imagen original y la imagen reconstruida, respectivamente, y n es el número total de píxeles. Al calcular el promedio de los errores absolutos, el MAE ofrece una medida directa de la magnitud de discrepancias entre las imágenes sin penalizar los errores pequeños.

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |x_i - y_i| \quad (3.2)$$

3.3.2 Error Cuadrático Medio

El error cuadrático medio, MSE de sus siglas en inglés, junto al MAE, es una de las métricas más utilizadas para la evaluación de modelos de regresión, y también se adapta para evaluar la calidad en la reconstrucción de imágenes. Esta métrica mide la media de las diferencias cuadradas entre los valores de los píxeles de dos imágenes [7]. Se define mediante la siguiente función 3.3, donde x_i y y_i representan los valores de los píxeles en la imagen original y la imagen reconstruida, respectivamente, y n es el número total de píxeles. A diferencia del MAE, el MSE amplifica los errores más grandes al elevarlos al cuadrado, pudiendo resaltar las áreas de mayor distorsión en la imagen.

$$\text{MSE} = \frac{1}{n} \sum_{i=1}^n (x_i - y_i)^2 \quad (3.3)$$

3.3.3 Peak Signal-to-Noise Ratio

El PSNR es una métrica cuantitativa ampliamente utilizada para evaluar la calidad en la reconstrucción de imágenes y vídeos [7]. Esta métrica mide la relación entre la potencia máxima de una señal y la potencia del ruido que afecta [24], y se define por la siguiente ecuación 3.4, donde MAX_I representa el valor máximo que puede tomar un píxel en la imagen original. Un valor más alto de PSNR indica una mayor similitud entre las imágenes comparadas, implicando que el proceso de comprensión y reconstrucción del modelo introduce una baja distorsión. Todos estos factores hacen que el PSNR sea especialmente útil para evaluar métodos de comprensión de imágenes, técnicas de superresolución y algoritmos de eliminación de ruido, proporcionando una medida sobre el rendimiento del modelo.

$$\text{PSNR} = 10 \cdot \log_{10} \left(\frac{\text{MAX}_I^2}{\text{MSE}} \right) \quad (3.4)$$

3.3.4 Structural Similarity Index Measure

La métrica SSIM, propuesta en [30], busca cuantificar la similitud estructural entre dos imágenes evaluando los cambios estructurales, la luminancia y el contraste. A diferencia de las otras métricas que se enfocan en la magnitud de los errores de los píxeles, el SSIM evalúa las degradaciones entre dos imágenes más relevante para la visión humana. Esto permite que el SSIM proporcione una representación más precisa a las percepciones visuales humanas en comparación con las otras métricas [7]. Esta métrica se define por la ecuación 3.5, donde μ_x y μ_y representan las medias locales de las imágenes x e y . Por otro lado, σ_x^2 y σ_y^2 son las varianzas locales de x e y . Mientras que σ_{xy} representa la covarianza local de x e y . Además, se utilizan dos constantes estabilizadoras, C_1 y C_2 , para evitar divisiones entre cero. El valor resultante del SSIM oscila entre -1 y 1, donde 1 indica que las imágenes comparadas son idénticas.

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (3.5)$$

Capítulo 4

Resultados

En este capítulo se presentan los resultados de evaluación de los distintos modelos implementados para cada una de las técnicas de mejora de imágenes estudiadas, permitiendo establecer una comparación entre ellos. Para el entrenamiento de los modelos se ha empleado un equipo que cuenta con una GPU NVIDIA GeForce RTX 4060 Ti 16GB y 32 GB de RAM. Tanto el entrenamiento de los modelos, como los resultados presentados a continuación, están incluidos en el repositorio de GitHub https://github.com/JaimeGlez22/Image_Enhancement_Resnet.

4.1 Eliminación de ruido en imágenes en blanco y negro

A continuación se presentan los resultados obtenidos tras el entrenamiento de los diferentes modelos propuestos para la eliminación de ruido en imágenes en blanco y negro. Para esta tarea se utiliza el conjunto de datos MNIST, adaptado a esta mediante el preprocesado descrito en la sección 3.1.1. La entrada de los modelos van a ser las imágenes de la colección con el ruido gaussiano añadido, y el objetivo es restaurarlas a su versión original sin ruido. El empleo de un dataset más sencillo, como el MNIST, convierte este entrenamiento en un primer acercamiento para verificar si las arquitecturas propuestas pueden ser útiles para las diversas técnicas de *image enhancement* estudiadas.

En el proceso de entrenamiento se emplea el 10 % de las muestras del conjunto de entrenamiento para conformar un subconjunto de validación. Este subconjunto permite evaluar el rendimiento, prevenir el sobreajuste y optimizar los hiperparámetros del modelo, garantizado su capacidad para generalizar a nuevos datos. Además se implementa una condición de parada, donde el entrenamiento se detiene restaurando los pesos correspondientes a la mejor iteración si no se consigue disminuir la pérdida del conjunto de validación en cinco iteraciones. En esta tarea se ha decidido emplear la función de pérdida *binary cross-entropy* y el optimizador Adam.

En la Tabla 4.1, se recopilan los hiperparámetros finales de cada una de las arquitecturas, así como el número de épocas completadas durante el entrenamiento y la duración total de este. En la cuarta columna correspondiente al número de épocas, se hace uso de un asterisco para señalar que se ha activado la condición de parada, indicando en la columna la iteración con mejor rendimiento cuyos pesos son los que finalmente emplea el modelo. A partir de los

datos de la tabla, se establece que el modelo que más tarda en converger a una solución es el VGGAE-19, requiriendo emplear el máximo de épocas establecido en treinta, tardando 1560 segundos en total. Por otro lado, en las arquitecturas ResNetAE se observa que, aunque la ResNetAE-50 es la que converge en el menor número de épocas, es la ResNetAE-18 la que finaliza el entrenamiento en el menor tiempo, tardando 804 segundos.

Tabla 4.1: Hiperparámetros y duración del entrenamiento de los modelos para la eliminación de ruido en imágenes en blanco y negro.

Modelo	Tamaño Batch	Tasa Aprendizaje	#épocas	Duración
ResNetAE-18	64	0,001	19*	804s
ResNetAE-34	64	0,001	21*	1179s
ResNetAE-50	64	0,0005	16*	1017s
VGGAE-16	64	0,0001	20*	700s
VGGAE-19	32	0,00007	30	1560s

Una vez entrenados los modelos, se emplea el conjunto de prueba para evaluar su rendimiento. Estas imágenes, pertenecientes a la colección MNIST, se les ha añadido un ruido gaussiano y no han sido utilizadas en el entrenamiento de los modelos, lo que va a permitir evaluar la capacidad de generalización de cada modelo para eliminar el ruido en imágenes que no han sido vistas con anterioridad por estos.

Para la evaluación se pasa cada imagen ruidosa del conjunto de prueba a través del modelo, obteniendo una imagen reconstruida sin ruido que se compara con la original. Para obtener valores objetivos que permitan un análisis del desempeño de los modelos se hace uso de las métricas descritas en la sección 3.3, error medio absoluto (MAE), error cuadrático medio (MSE), *Peak Signal-to-Noise Ratio* (PSNR) y *Structural Similarity Index Measure* (SSIM).

Tabla 4.2: Resultados de la evaluación de los modelos para la eliminación de ruido en imágenes en blanco y negro.

Modelo	MAE	MSE	PSNR	SSIM
ResNetAE-18	0,0355±0,088	0,0090±0,039	20,9633±2,264	0,8655±0,055
ResNetAE-34	0,0365±0,091	0,0096±0,041	20,6875±2,216	0,8601±0,056
ResNetAE-50	0,0404±0,094	0,0105±0,044	20,3598±2,390	0,8279±0,060
VGGAE-16	0,0432±0,103	0,0125±0,050	19,8094±2,751	0,8233±0,089
VGGAE-19	0,0522±0,117	0,0163±0,060	18,6722±2,843	0,7766±0,102

La Tabla 4.2 recopila los resultados obtenidos en la evaluación de cada modelo para la eliminación de ruido en imágenes en blanco y negro permitiendo establecer una comparación del desempeño que presentan. Los resultados muestran que el ResNetAE-18 ofrece el mejor rendimiento, con los valores más bajos de MAE y MSE, así como los valores más altos de PSNR y SSIM, superando a arquitecturas más complejas como ResNetAE-50 y VGGAE-19, siendo esta última la que peores resultados obtiene. Además, los resultados sugieren una ventaja en el empleo de las arquitecturas basadas en redes residuales para la eliminación de ruido, en comparación con los modelos que emplean las VGGs. Otra conclusión que se obtiene

de este análisis, es que en ciertas tareas con conjuntos de datos más simples, como ocurre en este caso, modelos menos complejos pueden ofrecer una mayor eficacia, destacando que un mayor número de parámetros no siempre se traduce en una mejora del rendimiento.




Figura 4.1: Ejemplo de eliminación de ruido en imágenes en blanco y negro.

Adicionalmente, se analizan visualmente varios ejemplos de imágenes del conjunto de prueba a los que se han aplicado los modelos de eliminación de ruido, permitiendo realizar una evaluación cualitativa de la efectividad que presentan estos modelos. Estos ejemplos se ven representados en la Figura 4.1, donde la primera columna contiene las imágenes originales. En la segunda columna se muestran estas mismas imágenes con el ruido gaussiano de $\sigma = 0,6$ añadido una vez las imágenes estaban normalizadas. Las siguientes cinco columnas recopilan las salidas de los diferentes modelos implementados. En estos ejemplos, se observa que todos los modelos consiguen reconstruir el dígito original, sin poder apreciarse diferencias visuales significativas entre las reconstrucciones de cada modelo.

4.2 Eliminación de ruido en imágenes a color

En la anterior sección se presentaban los resultados de la evaluación de los modelos para la eliminación de ruido en imágenes en blanco y negro, pero dado que actualmente la mayor parte de las imágenes que se toman son a color, se ha decidido estudiar, también, la eliminación de ruido en imágenes a color. En el entrenamiento de las redes para resolver esta tarea, se utiliza la colección *Thumbnails 128x128*, adaptada mediante el preprocesado descrito en la sección 3.1.2 para eliminar ruido de imágenes a color. La entrada a los AE van a ser las imágenes de tres canales a las que se les ha añadido el ruido gaussiano, siendo su objetivo restaurarlas a su versión original sin ruido.

Al igual que en la tarea anterior, en el proceso de entrenamiento se emplea un 10% de las muestras del conjunto de entrenamiento como subconjunto de validación, permitiendo evaluar el rendimiento del modelo y garantizar una buena generalización en datos nunca vistos. También, se establece una condición de parada temprana dependiente del valor de pérdida del conjunto de validación, restaurando los pesos de la mejor iteración si tras 5 épocas no consigue mejorar. Para esta tarea se ha empleado como función de pérdida el *mean squared error* y se hace uso del optimizador Adam.

La Tabla 4.3 recopila los hiperparámetros finales de cada una de las arquitecturas, así como el número de épocas requeridas y el tiempo total en completar el entrenamiento. En el entrenamiento de los modelos para la resolución de esta tarea no ha sido necesario la activación de la parada temprana, llegando todos los modelos al máximo de 30 épocas establecido. De estos datos podemos concluir que el modelo que más tarda en converger es ResNetAE-50, con un tiempo aproximado de más de 3 minutos por época. Este lento entrenamiento puede deberse al tamaño del *batch* empleado, establecido en 16 para este modelo, con el objetivo de poder ser alojado en la memoria disponible. A pesar de ello, los otros dos modelos ResNetAE muestran ser capaces de entrenarse más rápido que los VGGAE, siendo el modelo más pequeño ResNetAE-18 el que más rápido entrena con un tiempo aproximado de 1 minuto por época.

Tabla 4.3: Hiperparámetros y duración del entrenamiento de los modelos para la eliminación de ruido en imágenes a color.

Modelo	Tamaño Batch	Tasa Aprendizaje	#épocas	Duración
ResNetAE-18	64	0,0001	30	1899s
ResNetAE-34	32	0,0001	30	3013s
ResNetAE-50	16	0,0001	30	5803s
VGGAE-16	64	0,0001	30	3167s
VGGAE-19	64	0,0001	30	3737s

Una vez se cuenta con los modelos entrenados, se busca evaluar el desempeño de cada uno de ellos haciendo uso del conjunto de prueba. Las imágenes que conforman este conjunto, pertenecen también a la colección *Thumbnails 128x128* a las que se le añade el ruido gaussiano y que no fueron utilizadas en el proceso de entrenamiento. Permitiendo evaluar la capacidad de generalización de los modelos para eliminar ruido en imágenes a color que no han visto previamente.

Como en el caso anterior, se pasan las imágenes ruidosas del conjunto de prueba por el modelo, lo que permite obtener la imagen reconstruida sin ruido y compararla con la imagen original. Se ha hecho empleo de las mismas métricas, permitiendo cuantificar el desempeño de los modelos para resolver esta tarea.

Tabla 4.4: Resultados de la evaluación de los modelos para la eliminación de ruido en imágenes a color.

Modelo	MAE	MSE	PSNR	SSIM
ResNetAE-18	0,0439 $\pm$ 0,040	0,0040$\pm$0,010	24,2767 $\pm$ 1,637	0,7332 $\pm$ 0,052
ResNetAE-34	0,0432$\pm$0,041	0,0040$\pm$0,010	24,3055$\pm$1,733	0,7386$\pm$0,055
ResNetAE-50	0,0438 $\pm$ 0,042	0,0042 $\pm$ 0,011	24,1440 $\pm$ 1,760	0,7345 $\pm$ 0,056
VGGAE-16	0,0516 $\pm$ 0,050	0,0052 $\pm$ 0,014	22,7698 $\pm$ 1,960	0,6578 $\pm$ 0,072
VGGAE-19	0,0547 $\pm$ 0,053	0,0066 $\pm$ 0,016	22,2844 $\pm$ 1,957	0,6312 $\pm$ 0,077

La tabla 4.4 recopila los valores obtenidos para las diferentes métricas en la evaluación de cada modelo para la eliminación de ruido en imágenes a color. Los resultados de estas métricas permiten establecer una comparación sobre el desempeño que tienen los diferentes modelos entrenados. Los resultados muestran que el ResNetAE-34 es el modelo que ofrece mejor rendimiento, con los valores de MAE y MSE más bajos, siendo este último igual al resultado obtenido por el modelo ResNetAE-18, así como los valores más altos de PSNR y SSIM, superando a arquitecturas más complejas como ResNetAE-50. No existe una gran diferencia en el rendimiento entre los modelos ResNetAE, de acuerdo con estas métricas. Pero como ocurría en la anterior tarea, las arquitecturas basadas en redes residuales han demostrado tener un mejor desempeño que los VGGAE. También es importante resaltar que el modelo que peor evaluación presenta es el VGGAE-19, con los valores más altos de MAE y MSE, así como, valores más bajos de PSNR y SSIM, siendo la arquitectura que peor preserva los detalles.

Adicionalmente, se realiza un análisis visual sobre varias salidas obtenidas por los modelos entrenados para eliminar ruido de imágenes a color. Estos ejemplos son provenientes del conjunto de prueba y permiten establecer una evaluación cualitativa de la efectividad de estos modelos. La Figura 4.2 recopila 5 ejemplos donde en la primera columna se muestra la imagen original. La segunda columna muestra la imagen tras añadir el ruido gaussiano con $\sigma = 0,2$, aplicado tras la normalización de las imágenes. Y por último, las siguientes cinco columnas recopilan la salidas de los diferentes modelos implementados.

Los últimos dos ejemplos de la Figura 4.2, ponen de manifiesto como los modelos ResNetAE tienen una mayor capacidad para preservar los detalles de las imágenes, siendo capaces de mantener el mismo fondo en la imagen de salida que se aprecia en la original, no ocurre lo mismo por parte de los modelos VGGAE. Además, también se aprecia como las imágenes reconstruidas por los modelos VGGAE en todos los casos parecen ser más borrosas que las imágenes generadas por los modelos ResNetAE. Las imágenes obtenidas tras la aplicación de los diferentes modelos ResNetAE, no muestran una excesiva diferencia entre ellas, dificultando establecer cual es la arquitectura que mejor resultado obtiene basándose en el análisis visual.

Tras realizar el análisis visual y cuantitativo con el empleo de las métricas se puede concluir que




Figura 4.2: Ejemplo de eliminación de ruido en imágenes a color.

el modelo que mejor eficacia demuestra para la eliminación de ruido es el modelo ResNetAE-34. Aunque, bien es cierto que la diferencia no es demasiado considerable respecto al resto de arquitecturas ResNetAE. Lo que si dejan claros estos resultados es que las redes residuales muestran ser más efectivas para esta clase de tareas superando con creces a los modelos VGGAE.

4.3 Coloreado de imágenes

Otra de las técnicas de *image enhancement* en las que se han evaluado las arquitecturas ResNetAE es el coloreado de imágenes. Cabe destacar que en la evaluación de esta tarea solo se presentan los resultados obtenidos por los autoencoder basados en ResNet, ya que no se ha logrado establecer una configuración de entrenamiento efectiva para los VGGAE. Para el entrenamiento de estos modelos, se ha empleado la colección de imágenes *Landscape Image* descrita en la sección 3.1.3. Estos modelos toman como entrada las imágenes en escala de

grises con el objetivo de recuperar el color original de la imagen.

Durante el proceso de entrenamiento se ha utilizado un 10 % de las muestras del conjunto de entrenamiento para conformar un subconjunto de validación. Este conjunto de validación permite evaluar la capacidad de generalización de los modelos mientras se van entrenando. Además, se implementa una condición de parada dependiente del valor de pérdida del conjunto de validación, restaurándose los pesos de la mejor iteración si tras cinco épocas no se consigue mejorar. Se ha establecido el *mean absolute error* como la función de pérdida, empleando el optimizador Adam para encontrar los pesos que minimizan dicha función.

La Tabla 4.5, recopila los hiperparámetros finales de cada una de las arquitecturas, así como el número de épocas completadas y la duración total del entrenamiento. Todos los modelos alcanzaron el número máximo de épocas establecido en 40. Como era previsible, la arquitectura menos menos compleja, ResNetAE-18, fue la que más rápido completó el entrenamiento, mientras que la red más compleja, ResNetAE-50, es la que más tiempo requiere para completar el entrenamiento.

Tabla 4.5: Hiperparámetros y duración del entrenamiento de los modelos ResNetAE para el coloreado de imágenes.

Modelo	Tamaño Batch	Tasa Aprendizaje	#épocas	Duración
ResNetAE-18	64	0,0001	40	1123s
ResNetAE-34	32	0,0001	40	1810s
ResNetAE-50	32	0,0001	40	3615s

Tras el entrenamiento de los modelos se realiza una visualización preliminar de algunas de las salidas generadas por estos modelos para muestras aleatorias del conjunto de prueba de la colección *Landscape Image*, recopiladas en la Figura 4.3. En estos ejemplos se aprecia como los modelos tienden a recuperar colores similares a los de las imágenes originales, aunque hay algunas excepciones, por ejemplo en la última fila donde la imagen original a color muestra un bosque con las hojas marrones mientras que las imágenes coloreadas obtenidas por los diferentes modelos ilustran la vegetación en color verde.

Además, este análisis visual revela que los modelos a pesar de ser capaces de restaurar los colores originales en las imágenes en blanco y negro, muestran un menor desempeño para conservar los detalles de las formas de la imagen original. Las reconstrucciones de todos los modelos resaltan esta problemática, generando imágenes borrosas y en las que son difíciles de distinguir las formas de los edificios o de los paisajes. Este efecto se ve también reflejado por las métricas estudiadas, cuyos resultados están recogidos en la Tabla 4.7, donde las métricas específicas de imágenes, SSIM y PSNR, muestran unos valores bastante bajos que evidencian la existencia de un problema por parte de estas arquitecturas para mantener los detalles y la calidad visual.

Esta limitación, puede ser subsanada mediante la introducción de modificaciones en las arquitecturas ResNetAE, que permitan mejorar el aprendizaje de los detalles correspondientes con las formas de la imagen. Con este objetivo, se propone añadir una *skip connection* similar a las empleadas por las redes neuronales U-Net, [21] entre la entrada del modelo y la salida




Figura 4.3: Ejemplo de coloreado de imágenes empleando ResNetAE.

del ResNetAE, seguida de una convolución con un filtro de tamaño 3×3 , con tres mapas de activación que corresponden con el número de canales que tienen las imágenes a color, como se observa en la Figura 4.4. En las redes U-Net, estas conexiones se emplean para conectar directamente las capas convolucionales del *encoder* con sus correspondientes capas del *decoder*, permitiendo la transmisión sin pérdida, que se produce en el proceso compresión y descompresión, de información de alto nivel. En estas conexiones las salidas de las capas del *encoder* se concatenan con las del *decoder*.

La inclusión de esta conexión entre la entrada y la salida del modelo ResNetAE pretende transmitir los detalles asociados a las formas, presentes en la imagen en blanco y negro, directamente a la salida del autoencoder, evitando que esta información se pierda. Además, esta estrategia puede facilitar el aprendizaje de la red al reducir la complejidad de las transformaciones, ya que los detalles finos como los bordes serán transmitidos directamente por el atajo implementado.

Para poder evaluar la efectividad de esta modificación se deben entrenar estos nuevos modelos, denominados como ResNetAE_skip. Las condiciones del entrenamiento son las mismas que




Figura 4.4: ResNetAE con skip connection.

las propuestas en el caso de las ResNetAE, contando con un subconjunto de validación conformado por un 10 % de las muestras del conjunto de entrenamiento. También se aplica la condición de parada restaurando los pesos de la mejor iteración si no se produce una mejora en el valor de pérdida del conjunto de validación durante 5 épocas. Por otro lado, la función de pérdida utilizada sigue siendo el *mean absolute error*, y al igual que en el entrenamiento de los ResNetAE se emplea el optimizador Adam.

En la Tabla 4.6 se recogen los hiperparámetros con los que se han entrenados cada arquitectura, así como el número de épocas completadas durante el entrenamiento y la duración total de este. Destacar que para el modelo ResNetAE-18_skip, se ha activado la condición de parada, restaurando los pesos de la iteración 48 que presentaba los mejores resultados. Como ocurre en el resto de entrenamientos el modelo menos complejo, ResNet-18_skip, es el que menor duración emplea en el entrenamiento, mientras que el modelo ResNetAE-50_skip tarda tres veces más en finalizar.

Tabla 4.6: Hiperparámetros y duración del entrenamiento de los modelos ResNetAE_skip para el coloreado de imágenes.

Modelo	Tamaño Batch	Tasa Aprendizaje	#épocas	Duración
ResNetAE-18_skip	64	0,001	48*	1609s
ResNetAE-34_skip	32	0,001	60	2773s
ResNetAE-50_skip	32	0,001	60	5415s


Una vez entrenados los modelos, se realiza la evaluación del desempeño de cada uno de ellos haciendo uso de las imágenes pertenecientes al conjunto de prueba. Estas imágenes, pertenecen a la colección *Landscape Image*, donde se cuenta con imágenes en escala de grises, que van a ser las entradas del modelo, y su respectiva imagen en color, que se emplea para comparar la imagen generada sin que ninguna de estas haya sido vista por el modelo previamente. Esta evaluación permite conocer la capacidad de generalización con la que cuenta el modelo para colorear nuevas imágenes. Se ha realizado un análisis cuantitativo del proceso de coloreado de cada modelo empleando las métricas descritas en la sección 3.3.

En la Tabla 4.7 se recogen los resultados obtenidos para cada modelo para cada métrica. Los

Tabla 4.7: Resultados de la evaluación de los modelos para el coloreado de imágenes.

Modelo	MAE	MSE	PSNR	SSIM
ResNetAE-18	0,0751±0,065	0,0109±0,023	20,1101±2,096	0,5389±0,133
ResNetAE-34	0,0756±0,066	0,0117±0,024	20,0379±2,591	0,5284±0,145
ResNetAE-50	0,0777±0,067	0,0118±0,024	19,8782±2,372	0,5226±0,140
ResNetAE-18_skip	0,0437±0,035	0,0044±0,008	25,0976±3,560	0,9388±0,036
ResNetAE-34_skip	0,0396±0,032	0,0036±0,007	25,9112±3,524	0,9445±0,037
ResNetAE-50_skip	0,0392±0,030	0,0032±0,006	26,2480±3,232	0,9530±0,027

resultados obtenidos confirman la hipótesis planteada con el diseño de las nuevas arquitecturas, ResNetAE_skip, donde la introducción de una nueva conexión entre la entrada y la salida del autoencoder ResNet inicialmente propuesto, consigue obtener una gran mejora para todas las métricas, siendo el modelo ResNetAE-50_skip el que mejor rendimiento presenta, con los valores más bajos de MAE y MSE, así como los valores de PSNR y SSIM más altos,


Figura 4.5: Ejemplo de coloreado de imágenes empleando ResNetAE_skip.

que sugieren una mejor capacidad para preservar los detalles. Además, otra conclusión que se obtiene de estos resultados es que para esta tarea los modelos más complejos parecen presentar una mejor eficacia.

Para complementar las conclusiones obtenidas con los resultados de las métricas estudiadas, se ha realizado un análisis visual sobre varios ejemplos del conjunto de prueba, permitiendo obtener una valoración cualitativa sobre la eficiencia de los modelos. La Figura 4.5 muestra las salidas generadas por las diferentes arquitecturas ResNetAE_skip entrenadas para los cinco mismos ejemplos ilustrados en la Figura 4.3, que mostraba las salidas de los modelos ResNetAE, permitiendo establecer una comparación visual entre ambos tipos de arquitecturas. En ambas figuras, la primera columna contiene las imágenes originales a color, mientras que la segunda columna muestra las imágenes en escala de grises. Las siguientes columnas recopilan las imágenes coloreadas generada por las diferentes redes entrenadas.

Claramente se puede apreciar lo que los resultados cuantitativos proporcionado por las métricas ya avanzaban, que las ResNetAE_skip se aprovechan de la *skip connection* para mantener la estructura de la imagen, y de los ResNetAE, para obtener el color de la imagen, lo que hace que las imágenes obtenidas sean de mayor calidad visual. En las salidas de los modelos recogidas en la Figura 4.5 se aprecia una reducción de la borrosidad de las imágenes generadas por los ResNetAE_skip respecto a los modelos ResNetAE, pudiendo distinguirse de manera más clara las formas de los paisajes y de los edificios. A pesar de ello, se siguen produciendo errores donde los colores de las imágenes generadas no son fieles a su imagen original correspondiente, como ocurre en la imagen del bosque de hojas marrones, última fila, donde la vegetación, al igual que ocurría con los ResNetAE, sigue coloreándose de verde.

4.4 Superresolución

La última técnica de *image enhancement* estudiada durante el desarrollo de este TFM es la superresolución. Para esta tarea se han entrenado las diferentes arquitecturas con el objetivo de aumentar la resolución de las imágenes de entrada. Empleando la colección de imágenes *Labeled Faces in the Wild*, que tuvo que ser adaptada a esta tarea mediante el preprocesado descrito en el apartado 3.1.4, obteniendo una imagen de menos resolución a partir de las imágenes originales. Estos modelos tendrán como entrada la imagen de baja resolución, siendo el objetivo generar como salida una imagen de alta resolución que recupere los detalles que se pierden cuando las imágenes tienen peor resolución.

Como ha ocurrido en todas las tareas anteriores, se reserva un 10 % del conjunto de entrenamiento para conformar el subconjunto de validación, lo que va a permitir contar con un conjunto de muestras para analizar la calidad del entrenamiento y la capacidad de generalización que tiene el modelo con datos nunca vistos. Para el entrenamiento se ha establecido una condición de parada temprana dependiente de la función de pérdida sobre el conjunto de validación, restaurando los pesos de la mejor iteración si tras 5 épocas no se mejora el rendimiento, deteniendo el proceso de entrenamiento. Para el proceso de aprendizaje de los modelos para la superresolución, se ha establecido el *mean squared error* como la función de pérdida, además de emplearse el optimizador Adam.

Tabla 4.8: Hiperparámetros y duración entrenamiento de los modelos para la superresolución de imágenes.

Modelo	Tamaño Batch	Tasa Aprendizaje	#épocas	Duración
ResNetAE-18	80	0,0005	22*	1458s
ResNetAE-34	64	0,0005	22*	2365s
ResNetAE-50	16	0,0003	10*	2413s
VGGAE-16	64	0,001	29*	2922s
VGGAE-19	32	0,0001	40	4180s

La Tabla 4.8 recoge los hiperparámetros finales de cada una de las arquitecturas, así como el número de épocas completadas durante el entrenamiento y la duración total que ha necesitado cada modelo para converger hacia una solución. En la columna correspondiente al número de épocas, se ha marcado con un asterisco aquellos modelos, en los que se ha activado la condición de parada, indicando la iteración en la que se obtuvo el mejor resultado. Cabe destacar un rápido aprendizaje por parte del modelo ResNetAE-50, que converge a una solución en 10 épocas, aunque el modelo que más rápido entrena es el ResNetAE-18. Mientras que el modelo que más tarda en completar su entrenamiento es el VGGAE-19, requiriendo emplear el número máximo de épocas que se había establecido en 40.

Tras el entrenamiento de cada modelo se procede a evaluar el rendimiento que tienen cada uno de ellos, empleando el conjunto de prueba para esta evaluación. Las imágenes que conforman este conjunto también pertenecen a la colección *Labeled Faces in the Wild*, donde se han obtenido imágenes de menor resolución a través del preprocesado realizado sobre ellas. A partir de estas imágenes se puede evaluar la capacidad de generalización y el rendimiento que presentan estos modelos para generar imágenes de mayor resolución a partir de imágenes de baja resolución. Para ello se pasan como entrada de estos modelos las imágenes de baja resolución, generando como salida la imagen reconstruida de alta resolución, siendo estas imágenes comparadas con sus correspondientes imágenes originales de alta resolución. Para esta evaluación se ha hecho empleo de las métricas descritas en la sección 3.3.

La tabla 4.9 contiene los resultados obtenidos por los diferentes modelos en las distintas métricas, permitiendo obtener unos valores cuantitativos sobre el desempeño de los modelos frente a imágenes que no han vistos previamente. Los resultados muestran que la red ResNetAE-34 es la que mejor rendimiento general tiene, con el menor MAE y MSE, y el mayor PSNR, lo que implica una mayor precisión en el proceso de reconstrucción de imágenes de alta calidad

Tabla 4.9: Resultados de la evaluación de los modelos para la superresolución de imágenes.

Modelo	MAE	MSE	PSNR	SSIM
ResNetAE-18	0,0448±0,044	0,0043±0,014	23,9911±1,603	0,7222±0,067
ResNetAE-34	0,0418±0,042	0,0039±0,013	24,4042±1,742	0,7188±0,068
ResNetAE-50	0,0424±0,045	0,0042±0,013	24,1833±1,743	0,7106±0,063
VGGAE-16	0,0490±0,054	0,0059±0,017	22,7282±1,883	0,6711±0,073
VGGAE-19	0,0438±0,049	0,0048±0,015	23,6296±1,943	0,7050±0,069

y una mejor preservación del detalle, mientras que el modelo ResNetAE-18 cuenta con el valor de SSIM más alto, sugiriendo una mejor capacidad para preservar la estructura de la imagen por parte de este modelo. Comparativamente, las arquitecturas basadas en VGG han presentado un rendimiento inferior, siendo el VGGAE-19 el que mejor resultado presenta entre las dos versiones de esta clase de redes de acuerdo con las métricas empleadas, lo que vuelve a demostrar que las redes basadas en ResNet son más eficaces en esta clase de tareas.



Figura 4.6: Ejemplo superresolución.

Con el objetivo de completar la evaluación del rendimiento de los modelos para la tarea de superresolución, se ha desarrollado un análisis visual sobre las imágenes que ofrecen como salida estos modelos. Para ello, en la Figura 4.6, se recopilan 5 muestras del conjunto de prueba donde se han aplicado los modelos sobre las imágenes de baja resolución, ubicadas en la segunda columna de la figura. Comparando las imágenes reconstruidas de mayor resolución generadas por las diferentes redes entrenadas, situadas en las últimas cinco columnas, respecto a la imagen original de alta resolución ubicada en la primera columna de la figura.

Observando las imágenes generadas por los modelos se puede apreciar un mejor desempeño de las redes basadas en redes residuales que las redes que emplean las VGG. Esta situación

se ve representada en las imágenes correspondientes a la cuarta fila, donde los modelos VGGAE a la hora de aumentar la resolución introducen la forma de una cara en el centro de la imagen que no se corresponde con la realidad. Entre las reconstrucciones obtenidas por los modelos ResNetAE, no se aprecia una gran diferencia entre las diferentes versiones, aunque si parece que los modelos ResNetAE-18 y ResNetAE-34 pueden tener un ligero mejor comportamiento que el modelo ResNetAE-50. A pesar de ser capaces de obtener una imagen de mayor resolución, donde es más fácil identificar los rasgos de las personas que en las imágenes de baja resolución, los detalles más pequeños, como las arrugas o pequeños detalles de la forma de los ojos, son difíciles que se consigan reproducir en las imágenes reconstruidas por los modelos.

Capítulo 5

Conclusiones

A lo largo de este trabajo se ha buscado desarrollar unos modelos que fuesen capaces de adaptar las redes residuales ResNet en tareas de *image enhancement*, es decir, en técnicas del campo de la visión computacional para la mejora de la calidad visual de las imágenes, con el objetivo de evaluar el funcionamiento de esta clase de redes para diferentes técnicas de mejora de imágenes, como son la eliminación de ruido en imágenes, tanto en fotografías a color como en blanco y negro, el coloreado de imágenes y la superresolución. Buscando probar que el empleo de la novedosa introducción que proponen las ResNet, las conexiones residuales o *skip connections* también suponen una ventaja en el campo del *image enhancement* como ya han demostrado en otras tareas de la visión por computador, por ejemplo, en la clasificación de imágenes.

En este TFM se propone un diseño de arquitectura denominado ResNetAE. En el fondo, estas redes no se tratan más que de un *autoencoder* convolucional simétrico, donde el *encoder* hace empleo de arquitecturas ResNet ya propuestas en la literatura, con la diferencia de no contar con la capa densa final. La introducción de las conexiones residuales permite resolver problemas asociados al desarrollo de CNN más profundas, permitiendo desarrollar modelos más complejos que obtengan una mejor representación compacta de la imagen por parte del *encoder*. Además, para el *decoder*, se han tenido que implementar unos bloques residuales inversos, simétricos a los bloques del *encoder*, que emplean convoluciones transpuestas con el objetivo de reconstruir la imagen. En este diseño se busca combinar el buen impacto que han tenido los *autoencoders* en tareas de reconstrucción y mejora de imágenes, con las redes ResNet. Se han diseñado y entrenado diferentes versiones dependiendo de la arquitectura ResNet original en las que están basadas, por ejemplo, la red ResNetAE-18 emplea en el *encoder* el diseño propuesto por la red ResNet-18, mientras que el ResNetAE-34 o el ResNetAE-50 están basados en la arquitectura ResNet-34 y ResNet-50, respectivamente.

Con el objetivo de poder comparar las ventajas que aportan las redes ResNet se han construido unos modelos similares a los ResNetAE, es decir, unos CAE simétricos que hacen uso de otro tipo de red convolucional, las redes neuronales VGG. Para estas nuevas arquitecturas, el *encoder* empleará diseños de redes VGG propuestos en la literatura, VGG-16 y VGG-19, cada uno con su configuración de bloques secuenciales de capas convolucionales seguidas de un *max-pooling*. Al igual que ocurre en las arquitecturas ResNet no se hace empleo de las capas

densas. Para el *decoder*, se han implementado bloques secuenciales inversos que emplean capas de convolución transpuesta para obtener la imagen reconstruida a partir de la representación compacta del *encoder*.

Los resultados obtenidos en todas las tareas de mejora de imágenes donde se han empleado estos diseños muestran un mejor rendimiento de los modelos basados en ResNet, habiendo llegado incluso a no encontrar una configuración de entrenamiento que permitiese aprender a los VGGAE en la tarea de coloreado. Esto permite concluir que el empleo de las redes ResNet y sus conexiones residuales tienen un impacto positivo en el rendimiento de los modelos para la mejora de imágenes, siendo más evidente cuanto más compleja es la tarea a resolver.

Centrando el análisis en cada una de las tareas específicas estudiadas, se observa que en el primer caso, es decir, la eliminación del ruido en las imágenes de la colección MNIST, el modelo que mejores resultado obtiene es ResNetAE-18, aunque la diferencia con el resto de versiones ResNetAE no es excesivamente grande. Esto sugiere que para tareas más sencillas donde se cuenta con colecciones menos complejas, es más recomendable de modelos más simples que el empleo de diseños más complejos con un mayor número de parámetros, y por tanto un tiempo de entrenamiento superior.

En el caso concreto de la eliminación de ruido en imágenes a color se obtienen unos resultados muy ajustados entre las diferentes versiones de las arquitecturas ResNetAE, siendo estos bastante mejores que los obtenidos por los VGGAE. Esta situación complica determinar que versión de arquitectura ResNetAE emplear, ya que los resultados con todos ellos van a ser generalmente buenos y dependerá de cada caso concreto determinar con que salida quedarse.

Posiblemente la tarea del coloreado es la que mayor complejidad puede presentar, al tener que recuperar el color de las imágenes originales mientras se mantienen detalles de la imagen como la forma de los elementos fotografiados. Es por ello que ha sido necesario incluir una modificación en el diseño original de las ResNetAE, al no ser estos capaces de preservar los detalles obteniendo formas más borrosas, pero en general son capaces de restaurar unos colores bastante similares a los originales. Los modelos que introducen el atajo entre la entrada y la salida del modelo se han denominado ResNetAE_skip, y han supuesto una gran mejora de los resultados. Para esta tarea se ha detectado que un modelo más complejo como el ResNetAE-50_skip presenta unos mejores resultados, por tanto, siendo recomendable el empleo de versiones más complejas para el coloreado de imágenes. Dependiendo de las necesidades y capacidades de cómputo disponibles pueden emplearse versiones más simples dado que obtienen unos resultados aceptables, ligeramente inferiores.

Por último, en la tarea de superresolución los resultados muestran que la versión más simple, ResNetAE-18, de acuerdo con la métrica SSIM, muestra una mejor capacidad para conservar la estructura de la imagen de alta resolución. Aunque esta red para el resto de métricas empleadas es la que peor resultados obtiene de entre las versiones de modelos ResNetAE. No existe una gran diferencia entre las otras dos versiones, pero es la red ResNet-34 la que parece mostrar un mejor rendimiento. Lo que si existe es una gran diferencia con respecto a las redes VGGAE, que muestran unos peores resultados.

5.1 Limitaciones del trabajo

En este TFM se ha conseguido demostrar el buen desempeño que las redes residuales pueden tener en diversas técnicas de mejora de imágenes, obteniendo modelos capaces de resolver con buenos resultados las tareas para las que han sido entrenados. Aunque se ha establecido una comparación con otras clases de arquitecturas, demostrando unos mejores resultados en las arquitecturas que emplean las conexiones residuales, sería conveniente realizar una comparación con otros métodos que se encuentren en el estado del arte para complementar los hallazgos de este estudio.

Otra de las limitaciones que tiene un gran impacto en el modelo son las colecciones de imágenes empleadas. El tamaño de las colecciones, aunque son suficientes para la realización de estos experimentos, pueden no ser representativos en aplicaciones reales. Hay que tener en cuenta que la mayoría de las colecciones son sintéticas, es decir, ha sido necesario establecer un preprocesado para adaptarlas a las tareas que se buscaban realizar, lo que puede limitar su efectividad en contextos diferentes a los del entorno de estudio.

A pesar de contar con una GPU, se ha experimentado limitaciones de computo que también han marcado el desarrollo de este trabajo. Una mayor complejidad y profundidad de la red demanda grandes cantidades de recursos computacionales, sobre todo en el entrenamiento de los modelos, imposibilitando explorar el rendimiento de arquitecturas más complejas o con tamaños más grandes de lotes, todo esto limitó la cantidad de pruebas que se pudieron realizar para encontrar la configuración más óptima.

5.2 Líneas futuras

A partir de las limitaciones encontradas en el desarrollo del TFM, se propone una serie de líneas futuras que podrían explorarse con el fin de mejorar el rendimiento de las arquitecturas y evaluar su impacto.

- **Exploración de hiperparámetros:** una de las formas más sencillas y rápidas de mejorar el rendimiento de los modelos, es mediante el reentrenamiento modificando ciertos parámetros de la configuración del proceso de entrenamiento. Ajustes en hiperparámetros, como la tasa de aprendizaje o el tamaño del lote, pueden incrementar la capacidad aprendizaje y desempeño de una red.
- **Modificaciones de los diseños:** la inclusión de modificaciones en las arquitecturas, como se hizo para el coloreado de imágenes, puede mejorar la capacidad que tienen los modelos para resolver ciertas tareas. Por ejemplo, se podría probar si el diseño ResNetAE_skip también mejora el desempeño en otras tareas. Aunque en el caso de la eliminación de ruido no parece factible, ya que la conexión podría facilitar la transmisión del ruido a través del atajo.
- **Empleo de nuevas colecciones de imágenes:** utilizar nuevas colecciones con una mayor variedad suele aumentar la capacidad de generalización de los modelos para su empleo en casos reales. Además, el contar con colecciones extensas, permite al modelo aprender múltiples situaciones mejorando su rendimiento en distintos contextos.

- **Evaluación contra *Benchmarks*:** evaluar los modelos respecto a *benchmarks* públicos permite establecer una comparación directa con otros modelos para resolver la misma tarea.

Bibliografía

- [1] Bank, D., Koenigstein, N., Giryes, R., 2021. Autoencoders. URL: <http://arxiv.org/abs/2003.05991>, doi:[10.48550/arXiv.2003.05991](https://doi.org/10.48550/arXiv.2003.05991). arXiv:2003.05991 [cs, stat].
- [2] Breiman, L., 2001. Random Forests. Machine Learning 45, 5–32. URL: <https://doi.org/10.1023/A:1010933404324>, doi:[10.1023/A:1010933404324](https://doi.org/10.1023/A:1010933404324).
- [3] Cheng, Z., Sun, H., Takeuchi, M., Katto, J., 2018. Deep convolutional autoencoder-based lossy image compression, in: 2018 Picture Coding Symposium (PCS), pp. 253–257. doi:[10.1109/PCS.2018.8456308](https://doi.org/10.1109/PCS.2018.8456308).
- [4] Fan, L., Zhang, F., Fan, H., Zhang, C., 2019. Brief review of image denoising techniques. Visual Computing for Industry, Biomedicine, and Art 2, 7. URL: <https://doi.org/10.1186/s42492-019-0016-7>, doi:[10.1186/s42492-019-0016-7](https://doi.org/10.1186/s42492-019-0016-7).
- [5] Gao, W., Zhang, X., Yang, L., Liu, H., 2010. An improved sobel edge detection, in: 2010 3rd International Conference on Computer Science and Information Technology, pp. 67–71. doi:[10.1109/ICCSIT.2010.5563693](https://doi.org/10.1109/ICCSIT.2010.5563693).
- [6] Gondara, L., 2016. Medical image denoising using convolutional denoising autoencoders, in: 2016 IEEE 16th International Conference on Data Mining Workshops (ICDMW), pp. 241–246. doi:[10.1109/ICDMW.2016.0041](https://doi.org/10.1109/ICDMW.2016.0041).
- [7] Guerreiro, J., Tomás, P., Garcia, N., Aidos, H., 2023. Super-resolution of magnetic resonance images using generative adversarial networks. Computerized Medical Imaging and Graphics 108, 102280. URL: <https://www.sciencedirect.com/science/article/pii/S0895611123000988>, doi:<https://doi.org/10.1016/j.compmedimag.2023.102280>.
- [8] He, K., Zhang, X., Ren, S., Sun, J., 2016. Deep residual learning for image recognition, in: 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 770–778. doi:[10.1109/CVPR.2016.90](https://doi.org/10.1109/CVPR.2016.90).
- [9] Huang, G.B., Mattar, M., Berg, T., Learned-Miller, E., 2008. Labeled Faces in the Wild: A Database for Studying Face Recognition in Unconstrained Environments, in: Workshop on Faces in 'Real-Life' Images: Detection, Alignment, and Recognition, Erik Learned-Miller and Andras Ferencz and Frédéric Jurie, Marseille, France. URL: <https://inria.hal.science/inria-00321923>.
- [10] Kanchana, B., Peiris, R., Perera, D., Jayasinghe, D., Kasthurirathna, D., 2021. Computer

- vision for autonomous driving, in: 2021 3rd International Conference on Advancements in Computing (ICAC), pp. 175–180. doi:[10.1109/ICAC54203.2021.9671099](https://doi.org/10.1109/ICAC54203.2021.9671099).
- [11] Karras, T., Laine, S., Aila, T., 2019. A Style-Based Generator Architecture for Generative Adversarial Networks. URL: <http://arxiv.org/abs/1812.04948>, doi:[10.48550/arXiv.1812.04948](https://doi.org/10.48550/arXiv.1812.04948). arXiv:1812.04948 [cs, stat].
 - [12] Krizhevsky, A., Sutskever, I., Hinton, G.E., 2012. Imagenet classification with deep convolutional neural networks, in: Pereira, F., Burges, C., Bottou, L., Weinberger, K. (Eds.), Advances in Neural Information Processing Systems, Curran Associates, Inc. URL: https://proceedings.neurips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf.
 - [13] LeCun, Y., Bengio, Y., Hinton, G., 2015. Deep learning. Nature 521, 436–444. URL: <https://www.nature.com/articles/nature14539>, doi:[10.1038/nature14539](https://doi.org/10.1038/nature14539). publisher: Nature Publishing Group.
 - [14] Lecun, Y., Bottou, L., Bengio, Y., Haffner, P., 1998. Gradient-based learning applied to document recognition. Proceedings of the IEEE 86, 2278–2324. doi:[10.1109/5.726791](https://doi.org/10.1109/5.726791).
 - [15] Lee, H., Chen, Y.P.P., 2015. Image based computer aided diagnosis system for cancer detection. Expert Systems with Applications 42, 5356–5365. URL: <https://www.sciencedirect.com/science/article/pii/S0957417415000986>, doi:<https://doi.org/10.1016/j.eswa.2015.02.005>.
 - [16] Litjens, G., Kooi, T., Bejnordi, B.E., Setio, A.A.A., Ciompi, F., Ghafoorian, M., van der Laak, J.A., van Ginneken, B., Sánchez, C.I., 2017. A survey on deep learning in medical image analysis. Medical Image Analysis 42, 60–88. URL: <https://www.sciencedirect.com/science/article/pii/S1361841517301135>, doi:<https://doi.org/10.1016/j.media.2017.07.005>.
 - [17] Mao, X., Shen, C., Yang, Y.B., 2016. Image restoration using very deep convolutional encoder-decoder networks with symmetric skip connections, in: Lee, D., Sugiyama, M., Luxburg, U., Guyon, I., Garnett, R. (Eds.), Advances in Neural Information Processing Systems, Curran Associates, Inc. URL: https://proceedings.neurips.cc/paper_files/paper/2016/file/0ed9422357395a0d4879191c66f4faa2-Paper.pdf.
 - [18] Nair, V., Hinton, G.E., 2010. Rectified linear units improve restricted boltzmann machines, in: Proceedings of the 27th International Conference on International Conference on Machine Learning, Omnipress, Madison, WI, USA. p. 807–814.
 - [19] Nečasová, T., Burgos, N., Svoboda, D., 2022. Chapter 25 - validation and evaluation metrics for medical and biomedical image synthesis, in: Burgos, N., Svoboda, D. (Eds.), Biomedical Image Synthesis and Simulation. Academic Press. The MICCAI Society book Series, pp. 573–600. URL: <https://www.sciencedirect.com/science/article/pii/B9780128243497000323>, doi:<https://doi.org/10.1016/B978-0-12-824349-7.00032-3>.
 - [20] Quinlan, J.R., 1986. Induction of decision trees. Machine Learning 1, 81–106. URL: <https://doi.org/10.1007/BF00116251>, doi:[10.1007/BF00116251](https://doi.org/10.1007/BF00116251).

- [21] Ronneberger, O., Fischer, P., Brox, T., 2015. U-Net: Convolutional Networks for Biomedical Image Segmentation, in: Navab, N., Hornegger, J., Wells, W.M., Frangi, A.F. (Eds.), Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015, Springer International Publishing, Cham. pp. 234–241. doi:[10.1007/978-3-319-24574-4_28](https://doi.org/10.1007/978-3-319-24574-4_28).
- [22] Roodschild, M., Gotay Sardiñas, J., Will, A., 2020. A new approach for the vanishing gradient problem on sigmoid activation. Progress in Artificial Intelligence 9, 351–360. URL: <https://doi.org/10.1007/s13748-020-00218-y>, doi:[10.1007/s13748-020-00218-y](https://doi.org/10.1007/s13748-020-00218-y).
- [23] Sancho, J., 2020. Machine Learning y Deep Learning. RA-MA S.A. Editorial y Publicaciones. URL: <https://books.google.es/books?id=2c-4EAAAQBAJ>.
- [24] Sethi, D., Bharti, S., Prakash, C., 2022. A comprehensive survey on gait analysis: History, parameters, approaches, pose estimation, and future work. Artificial Intelligence in Medicine 129, 102314. URL: <https://www.sciencedirect.com/science/article/pii/S0933365722000793>, doi:<https://doi.org/10.1016/j.artmed.2022.102314>.
- [25] Simonyan, K., Zisserman, A., 2015. Very Deep Convolutional Networks for Large-Scale Image Recognition. URL: <http://arxiv.org/abs/1409.1556>, doi:[10.48550/arXiv.1409.1556](https://doi.org/10.48550/arXiv.1409.1556). arXiv:1409.1556 [cs].
- [26] SuperDataScience, . Convolutional Neural Networks (CNN): Summary - Blogs - SuperDataScience | Machine Learning | AI | Data Science Career | Analytics | Success. URL: <https://www.superdatascience.com/blogs/convolutional-neural-networks-cnn-summary>.
- [27] Sushma, B., Aparna, P., 2021. Summarization of wireless capsule endoscopy video using deep feature matching and motion analysis. IEEE Access 9, 13691–13703. doi:[10.1109/ACCESS.2020.3044759](https://doi.org/10.1109/ACCESS.2020.3044759).
- [28] Sánchez, P., 2023. Desde la cámara oscura hasta el teléfono móvil: la historia de la fotografía. URL: https://historia.nationalgeographic.com.es/a/historia-fotografia-arte-dibujar-luz_20128.
- [29] Tian, H., Wang, T., Liu, Y., Qiao, X., Li, Y., 2020. Computer vision technology in agricultural automation —a review. Information Processing in Agriculture 7, 1–19. URL: <https://www.sciencedirect.com/science/article/pii/S2214317319301751>, doi:<https://doi.org/10.1016/j.inpa.2019.09.006>.
- [30] Wang, Z., Bovik, A., Sheikh, H., Simoncelli, E., 2004. Image quality assessment: from error visibility to structural similarity. IEEE Transactions on Image Processing 13, 600–612. doi:[10.1109/TIP.2003.819861](https://doi.org/10.1109/TIP.2003.819861).
- [31] Yann LeCun, C.C., Burges, C., . MNIST handwritten digit database,. URL: <http://yann.lecun.com/exdb/mnist/>.
- [32] Youkachen, S., Ruchanurucks, M., Phatrapomnant, T., Kaneko, H., 2019. Defect segmentation of hot-rolled steel strip surface by using convolutional auto-encoder and conventional image processing, in: 2019 10th International Conference of Informa-

- tion and Communication Technology for Embedded Systems (IC-ICTES), pp. 1–5. doi:[10.1109/ICTEmSys.2019.8695928](https://doi.org/10.1109/ICTEmSys.2019.8695928).
- [33] Yue, L., Shen, H., Li, J., Yuan, Q., Zhang, H., Zhang, L., 2016. Image super-resolution: The techniques, applications, and future. *Signal Processing* 128, 389–408. URL: <https://www.sciencedirect.com/science/article/pii/S0165168416300536>, doi:<https://doi.org/10.1016/j.sigpro.2016.05.002>.
- [34] Zhou, Y., Zhang, Y., Xie, X., Kung, S.Y., 2021. Image super-resolution based on dense convolutional auto-encoder blocks. *Neurocomputing* 423, 98–109. URL: <https://www.sciencedirect.com/science/article/pii/S0925231220314570>, doi:<https://doi.org/10.1016/j.neucom.2020.09.049>.
- [35] Žeger, I., Grgić, S., Vuković, J., Šišul, G., 2021. Grayscale image colorization methods: Overview and evaluation. *IEEE Access* 9, 113326–113346. doi:[10.1109/ACCESS.2021.3104515](https://doi.org/10.1109/ACCESS.2021.3104515).